

Exposição à Inteligência Artificial e Mercado de Trabalho no Brasil

Amostra, estatísticas descritivas e estratégia empírica

Manoel Brasil

Orientadora: Profa. Danyelle Karine Santos Branco
14 de Maio

Resumo da Apresentação

- ▶ **Etapa 1:** PNAD Contínua + índice ILO — quem está exposto à IA no Brasil?
- ▶ **Etapa 2:** Novo CAGED + DiD — ocupações expostas mudaram após o ChatGPT?
- ▶ **Etapa 3:** CAGED municipal + Anatel — conectividade amplifica o efeito?
- ▶ Para cada etapa: **amostra**, **estatísticas descritivas** e, quando houver inferência causal, **modelo econométrico**.

Pergunta de Pesquisa e Desenho Geral

Pergunta: a IA generativa já deixou sinais mensuráveis no mercado de trabalho brasileiro?

O desenho empírico avança em três camadas:

- ▶ Primeiro, mapeio a exposição ocupacional à IA na força de trabalho brasileira.
- ▶ Depois, testo se ocupações mais expostas tiveram trajetória diferente após o lançamento do ChatGPT.
- ▶ Por fim, verifico se o efeito é maior onde a infraestrutura digital facilita a difusão da tecnologia.

Etapa 1: PNADc + ILO

Etapa 1 — Construção da Base

Item	Valor
Fonte	PNADc 3T/2025 (IBGE) + ILO WP140
Observações na amostra	207.901
População representada	97,8 milhões
Unidades federativas	27
Ocupações COD	428
Cobertura de score	99,2%
Match a 4 dígitos	98,1%
Alta exposição (G3-G4)	9,8 milhões


- ▶ A unidade de observação é o trabalhador ocupado na PNADc.
- ▶ O peso amostral transforma a amostra em população representada.
- ▶ A variável central é o score ocupacional do ILO Global Index, associado à ocupação COD por crosswalk hierárquico.
- ▶ Tratamento de extremos: rendimento habitual limitado aos percentis ponderados 1 e 99.

Etapa 1 — Estatísticas Descritivas e Amostra

Variável	Unidade	N	Média	Desv. Pad.	Min	Max
Score de exposição ILO	0-1	206.230	0,28	0,15	0,09	0,70
Alta exposição (G3-G4)	%	207.901	10,00	30,00	0,00	100,00
Idade	anos	207.901	39,26	12,11	18,00	65,00
Nível de instrução	categoria	207.901	4,86	1,73	1,00	7,00
Rendimento habitual	R\$	204.142	3.417,54	4.795,91	10,00	250.000,00
Log rendimento habitual	log R\$	204.142	7,74	0,84	5,30	9,95
Horas habituais	horas/sem.	207.901	40,13	11,48	1,00	120,00
Mulheres	%	207.901	43,73	49,61	0,00	100,00
Branços	%	207.901	43,17	49,53	0,00	100,00
Trabalhadores formais	%	207.901	42,38	49,42	0,00	100,00

Leitura: esta tabela resume o corte transversal usado para descrever a exposição à IA. As médias são ponderadas pelo peso da PNADc, portanto representam a força de trabalho ocupada, não apenas a amostra observada.


Evidência Visual Preliminar — Distribuição



O que o gráfico mostra?

- ▶ A distribuição é assimétrica: muita massa em baixa exposição.
- ▶ Há uma cauda relevante de ocupações com exposição alta.
- ▶ A média sozinha esconde a heterogeneidade entre tipos de ocupação.

Evidência Visual Preliminar — Gradientes




Como interpretar os gradientes?

- ▶ Gradientes 1 e 2 indicam exposição parcial, mais próxima de complementaridade.
- ▶ Gradientes 3 e 4 indicam exposição alta e mais consistente entre tarefas.
- ▶ O grupo G3-G4 é a base conceitual para definir ocupações de alta exposição nas etapas causais.

Evidência Visual Preliminar — Perfil Demográfico

Distribuição da força de trabalho ocupada por nível de exposição à LG geradora
Porcentagem em São Paulo, Ceará, Bahia, Pernambuco e Rio de Janeiro — Brasil 2022



Padrão substantivo

- ▶ Mulheres, brancos, jovens e mais escolarizados aparecem mais em alta exposição.
- ▶ Esse padrão não é individual; reflete principalmente sorting ocupacional.
- ▶ A etapa 2 parte exatamente desse grupo de ocupações mais expostas.

Etapa 2: CAGED + ILO

Por que CAGED + Diferenças em Diferenças?

A etapa 1 é descritiva: mostra **quem está exposto**, mas não identifica efeito causal.

A etapa 2 muda a pergunta:

Após o lançamento do ChatGPT, ocupações altamente expostas à IA tiveram mudanças diferenciais em salário ou volume de admissões?

- ▶ O CAGED mede fluxos mensais do mercado formal.
- ▶ O evento é o lançamento do ChatGPT em novembro de 2022.
- ▶ O tratamento vem da exposição ocupacional medida pelo índice ILO.

Etapa 2 — Ficha Técnica do Painel

Item	Valor
Fonte	Novo CAGED + ILO WP140
Janela analítica	2021-01 a 2025-06
Movimentações CAGED agregadas	198,8 milhões
Células ocupação-mês do painel	32.988
Ocupações CBO 4d	629
Períodos mensais	54
Ocupações tratadas	131
Participação tratada	20,8%
Evento	Lançamento do ChatGPT (nov/2022)

- ▶ Unidade da regressão: ocupação CBO 4 dígitos $\times$ mês.
- ▶ As 32.988 células ocupação-mês resumem 198,8 milhões de movimentações individuais do CAGED.
- ▶ Tratamento de extremos: salários de admissão limitados aos percentis 1 e 99; logs recalculados após o ajuste.
- ▶ Grupo tratado: ocupações no top 20% do score ILO.

Etapa 2 — Estatísticas Descritivas dos Outcomes

Variável	Unidade	N	Média	Desv. Pad.	Min	Max
Admissões	vagas/mês	32.988	3.153,53	13.879,98	0,00	289.900,00
Desligamentos	vagas/mês	32.988	2.873,65	12.450,54	0,00	284.338,00
Saldo líquido	vagas/mês	32.988	279,88	2.323,00	-46.650,00	90.556,00
Salário admissão	R\$	32.988	6.131,12	158.475,43	0,00	18.799.538,19
Salário admissão	SM	32.988	4,74	120,53	0,00	15.511,17
Idade média	anos	32.988	33,23	5,43	0,00	73,00
Mulheres nas admissões	%	32.988	0,00	0,00	0,00	0,00
Superior nas admissões	%	32.988	21,47	26,43	0,00	100,00
Score ILO	0-1	32.988	0,28	0,12	0,12	0,63

Leitura: as variáveis de quantidade medem fluxos de emprego; as variáveis salariais medem preço do trabalho no momento da admissão, a margem mais limpa para capturar mudanças recentes de demanda.

Estratégia Empírica — Modelo da Etapa 2

Equação de regressão

$$y_{ot} = \beta (\text{Pós}_t \times \text{AltaExp}_o) + \gamma X_{ot} + \alpha_o + \delta_t + \varepsilon_{ot}$$

- ▶ o indexa ocupações CBO 4 dígitos.
- ▶ t indexa meses.
- ▶ A variação de interesse combina **antes/depois** do ChatGPT com **alta/baixa exposição** ocupacional.

Etapa 2 — Legenda Detalhada do Modelo

- ▶ y_{ot} é o outcome da ocupação o no mês t : log do salário real, log das admissões, desligamentos ou composição das admissões.
- ▶ AltaExp_o vale 1 para ocupações no top 20% do score ILO. Ela captura a diferença **transversal** entre ocupações mais e menos expostas.
- ▶ Pós_t vale 1 a partir de dezembro de 2022. Ela captura a diferença **temporal** após o lançamento do ChatGPT.
- ▶ β é o coeficiente de interesse: o efeito diferencial pós-ChatGPT nas ocupações altamente expostas, sob tendências paralelas.
- ▶ X_{ot} inclui controles que mudam ao longo do tempo, como idade média, participação feminina e participação com superior.

Etapa 2 — Efeitos Fixos e Erros-Padrão

- ▶ α_o é o efeito fixo de ocupação. Ele absorve diferenças permanentes entre ocupações, como prestígio, complexidade técnica e nível salarial estrutural.
- ▶ δ_t é o efeito fixo de mês. Ele absorve choques comuns a todo o mercado formal, como inflação, sazonalidade e ciclo macroeconômico.
- ▶ ε_{ot} é o erro idiossincrático.
- ▶ Os erros-padrão são clusterizados por CBO 4d, porque o tratamento varia no nível da ocupação.
- ▶ A hipótese central é: sem o ChatGPT, ocupações tratadas e controle seguiriam trajetórias paralelas.

Etapa 2 — Balanço Pré-Tratamento

Variável	Controle	Tratamento	Dif. norm.	Balanceado
Admissões	2.655,34	3.409,84	0,06	Sim
Desligamentos	2.321,33	2.916,92	0,06	Sim
Saldo líquido	334,01	492,92	0,09	Sim
Salário médio (R\$)	4.073,21	5.919,86	0,19	Sim
Idade média	32,75	31,80	-0,17	Sim
% mulheres	0,00	0,00	—	Não
% superior	15,57	41,89	1,15	Não

Leitura: as variáveis de fluxo são mais comparáveis no pré-tratamento. Salário, escolaridade e composição feminina são desbalanceados porque a própria exposição à IA está concentrada em ocupações *white collar*. Os efeitos fixos de ocupação tratam diferenças permanentes.

Etapa 3: CAGED + Anatel

Por que Adicionar Conectividade Municipal?

A IA generativa é uma tecnologia digital. Mesmo que duas ocupações tenham a mesma exposição técnica, a difusão pode ser maior onde há melhor infraestrutura de internet.

A etapa 3 testa se o canal ocupacional da etapa 2 é amplificado em municípios com maior conectividade.

- ▶ Unidade: município $\times$ ocupação $\times$ mês.
- ▶ Fonte de conectividade: indicadores municipais da Anatel.
- ▶ Estratégia: diferença-em-diferenças-em-diferenças.

Etapa 3 — Ficha Técnica do Painel Municipal

Item	Valor
Fonte	Novo CAGED + Anatel + IBGE + ILO WP140
Unidade do painel	Município $\times$ ocupação $\times$ mês
Janela analítica	2021-01 a 2025-06
Movimentações CAGED agregadas	161,9 milhões
Células município-ocupação-mês	5.534.808
Municípios	657
Ocupações CBO 4d	614
UFs	28
Alta conectividade	80,5%

- ▶ O painel municipal resume 161,9 milhões de movimentações em 5.534.808 células município-ocupação-mês.
- ▶ Essa granularidade permite comparar ocupações semelhantes em ambientes digitais diferentes.
- ▶ Tratamento de extremos: salário nominal e salário real de admissão limitados aos percentis 1 e 99.
- ▶ Alta conectividade é definida antes do tratamento, evitando que o próprio choque

Etapa 3 — Estatísticas Descritivas

Variável	Unidade	N	Média	Desv. Pad.	Min	Max
Admissões	vagas/mês	5.534.808	15,30	155,07	0,00	34.019,00
Desligamentos	vagas/mês	5.534.808	13,96	141,03	0,00	36.875,00
Saldo líquido	vagas/mês	5.534.808	1,35	33,95	-7.322,00	11.635,00
Salário real admissão	R\$ dez/2024	5.534.808	5.482,50	3.010.047,82	0,00	5.505.546.848,14
Idade média	anos	5.534.808	26,42	15,20	0,00	94,00
Mulheres nas admissões	%	5.534.808	26,88	37,94	0,00	100,00
Superior nas admissões	%	5.534.808	13,55	29,57	0,00	100,00
Jovens nas admissões	%	5.534.808	34,63	37,20	0,00	100,00
Score ILO	0-1	5.534.808	0,28	0,14	0,12	0,63
Penetração banda larga	%	5.534.808	64,34	24,61	2,06	127,27
Fibra no pré	%	5.534.808	0,00	0,00	0,00	0,00
PIB per capita	R\$	5.534.808	52.619,04	47.935,23	8.167,85	473.953,85

Etapa 3 — Conectividade e Amostra

Variável	Baixa conect.	Alta conect.	Diferença
Admissões	5,39	16,27	10,87
Salário real admissão	5.580,02	5.473,01	-107,01
Idade média	24,27	26,63	2,36
% mulheres	21,87	27,37	5,50
% superior	8,81	14,01	5,19
Score ILO	0,29	0,28	-0,00
Banda larga fixa	17,80	68,87	51,07
Fibra	0,00	0,00	0,00

Leitura: municípios de alta conectividade são estruturalmente diferentes. Por isso, a etapa 3 não compara apenas municípios conectados contra não conectados; ela usa a interação com exposição ocupacional e período pós-ChatGPT.

Estratégia Empírica — Modelo da Etapa 3

Equação Triple-DiD

$$\begin{aligned} y_{mot} = & \beta_1(\text{Pós}_t \times \text{AltaExp}_o) + \beta_2(\text{Pós}_t \times \text{AltaConect}_m) \\ & + \beta_3(\text{AltaExp}_o \times \text{AltaConect}_m) + \beta_4(\text{Pós}_t \times \text{AltaExp}_o \times \text{AltaConect}_m) \\ & + \gamma X_{mot} + \alpha_{mo} + \delta_t + \varepsilon_{mot} \end{aligned}$$

O foco é β_4 : o efeito adicional em ocupações expostas, no pós-ChatGPT, dentro de municípios mais conectados.

Etapa 3 — Legenda Detalhada do Triple-DiD

- ▶ m indexa municípios, o ocupações e t meses.
- ▶ AltaConect_m vale 1 para municípios acima do ponto de corte de conectividade no pré-tratamento.
- ▶ β_1 captura o canal ocupacional médio da etapa 2.
- ▶ β_2 captura mudanças pós-ChatGPT em municípios conectados para todas as ocupações.
- ▶ β_3 captura diferenças estruturais entre ocupações expostas localizadas em municípios conectados.
- ▶ β_4 isola a amplificação digital: exposição ocupacional alta **mais** capacidade local de difusão da tecnologia.

Etapa 3 — Efeitos Fixos e Identificação

- ▶ α_{mo} é o efeito fixo de município $\times$ ocupação.
- ▶ Ele compara a mesma ocupação dentro do mesmo município ao longo do tempo.
- ▶ Isso absorve diferenças permanentes, como estrutura produtiva local, nível salarial local e composição ocupacional fixa.
- ▶ δ_t remove choques agregados comuns a todos os municípios e ocupações.
- ▶ A identificação vem da diferença relativa pós-ChatGPT entre ocupações expostas e não expostas, em municípios com alta e baixa conectividade.

Mensagem central da apresentação

- ▶ A etapa 1 mostra a geografia social da exposição à IA no Brasil.
- ▶ A etapa 2 transforma essa exposição em tratamento econométrico.
- ▶ A etapa 3 testa o mecanismo de difusão: a infraestrutura digital pode amplificar o choque.
- ▶ As tabelas descritivas e de amostra são o elo entre dados brutos, especificação e interpretação.