



Dissertação de Mestrado V2

Status	Em andamento
Documentos	A1 - WP140_web.pdf - Generative AI and Jobs A Refined Global Index of Occupational Exposure , A2 - Canaries in the Coal Mine.pdf Canaries in the Coal Mine? Six Facts about the Recent Employment Effects of Artificial Intelligence , A3 - Economic Index Jan 14 2026.pdf
Resumo por IA	Dissertação de mestrado que desenvolve e aplica um índice de exposição ocupacional à inteligência artificial no Brasil, usando o ILO Global Index adaptado às classificações COD e CBO. Analisa a distribuição da exposição entre setores, regiões e grupos sociodemográficos, revelando que 10,1% da força de trabalho formal está em ocupações altamente expostas, predominantemente em funções administrativas e de apoio. Emprega painel mensal do CAGED e método de diferenças em diferenças para avaliar o impacto do lançamento do ChatGPT (nov/2022) sobre admissões, desligamentos e salários de entrada, encontrando redução significativa nos salários, mas efeitos insignificantes ou inconclusivos nos fluxos de emprego devido a falhas nas tendências paralelas. Explora heterogeneidades, destacando maior retração nas admissões e desligamentos entre trabalhadores negros e proteção relativa de trabalhadores de 41-49 anos, sem diferenças de gênero ou renda. Conclui que a exposição potencial não se traduz uniformemente em ajustes de mercado, sugerindo necessidade de monitoramento contínuo.

Introdução

A última geração de modelos de inteligência artificial, que ganhou visibilidade pública a partir do lançamento do ChatGPT 3.5, em novembro de 2022, ampliou, de forma inédita, a capacidade de automatizar ou complementar tarefas cognitivas. Diferentemente de ondas anteriores de automação, em que o alcance se concentrava em atividades manuais e rotineiras, os modelos de linguagem de grande escala (*Large Language Models*, LLMs) atingem ocupações de escritório, finanças, educação, tecnologia e gestão. Nos Estados Unidos, estima-se que 32,1% dos trabalhadores já integravam ferramentas de IA em suas rotinas até o final de 2024, num ritmo de adoção comparável ao do computador pessoal na década de 1980 e superior, em termos populacionais, ao da própria internet ([Bick; Blandin; Deming, 2024](#)). Essa combinação de alcance ocupacional e velocidade de difusão justifica tratar essa nova geração de modelos de inteligência artificial como um problema econômico, e não apenas tecnológico. A maneira que essa tecnologia se espalha por ocupações, seus efeitos potenciais sobre emprego, salários e desigualdade passam a ser uma questão central para a economia do trabalho.

A literatura internacional avançou em duas frentes. De um lado, consolidou-se uma metodologia de construção de índices de exposição baseados em tarefas, a partir do *GPT Exposure* de Eloundou *et al.* (2023), que passou a usar os próprios LLMs como avaliadores das tarefas. De outro, começou a se acumular evidência empírica sobre emprego e salários, com estudos recentes nos Estados Unidos e no Reino Unido convergindo para a conclusão de que o impacto da IA está se manifestando principalmente pela porta de entrada do mercado de trabalho, com recém-formados e trabalhadores jovens em ocupações expostas recebendo salários menores e enfrentando menor oferta de trabalho ([Brynjolfsson; Chandar; Chen, 2025](#); [Hosseini Maasoum; Lichtinger, 2025](#); [Klein Teeselink, 2025](#)). Essa evidência, no entanto, foi produzida quase inteiramente em economias de alta renda. Permanece uma lacuna importante quando o objeto é um país de renda média, com elevada informalidade, desigualdade racial e regional acentuada e uma estrutura ocupacional distinta da dos países desenvolvidos. É nessa lacuna que o Brasil se encaixa, e é ela que esta dissertação procura ajudar a preencher.

O objetivo desta dissertação é construir e aplicar uma medida de exposição ocupacional à inteligência artificial para o Brasil e investigar se ocupações mais expostas apresentaram mudanças diferenciais nos fluxos e nos salários do emprego formal após a difusão do ChatGPT. Para isso, o trabalho responde a duas perguntas: (i) quais trabalhadores e ocupações estão mais expostos à IA no Brasil? e (ii) ocupações formais mais expostas apresentaram mudanças diferenciais em admissões, desligamentos e salários após a difusão do ChatGPT? A primeira pergunta tem caráter descritivo e distributivo; a segunda, caráter empírico e exploratório sobre a dinâmica do emprego formal.

Para responder a essas perguntas, recorro a duas bases de dados com papéis distintos. A Pesquisa Nacional por Amostra de Domicílios Contínua (PNADc) sustenta a etapa descritiva: por sua representatividade e riqueza de variáveis

sociodemográficas, ela permite traçar um retrato de quem está exposto à IA no Brasil. O Cadastro Geral de Empregados e Desempregados (CAGED), por sua vez, sustenta a etapa empírica: como registro administrativo de cobertura plena do mercado formal, ele permite observar admissões, desligamentos e salários no tempo, viabilizando um desenho de diferenças em diferenças em torno do lançamento do ChatGPT. A PNAD responde quem está exposto; o CAGED, o que aconteceu com o emprego formal mais exposto.

A peça que conecta as duas etapas é o índice de exposição. Adotei o *ILO Global Index* (Gmyrek *et al.*, 2025) por dois motivos: ele é o único entre os principais índices estruturado em torno da ISCO-08, classificação internacional com maior compatibilidade com as taxonomias ocupacionais brasileiras, e é o de construção metodologicamente mais robusta, por combinar validação humana de tarefas com classificação assistida por LLMs. Aplicá-lo ao Brasil, no entanto, exigiu uma etapa de tradução: construí um *crosswalk* entre as classificações ocupacionais brasileiras (a COD, usada na PNAD, e a CBO, usada no CAGED) e a ISCO-08.

Antes de apresentar os primeiros achados do estudo, é importante deixar claro o que significa exposição ocupacional, que mede o potencial de a IA afetar as tarefas de uma ocupação. Uma ocupação está mais exposta quando uma parcela relevante de suas tarefas pode ser automatizada ou complementada por modelos de IA. Exposição não é impacto e não é um indicador de substituição. Vamos explorar essa distinção com mais profundidade na seção 2.

Os resultados descritivos, obtidos ao cruzar a PNADc do 3º trimestre de 2025 com o índice da OIT, cobrem 97,8 milhões de trabalhadores e mostram que 10,1% da força de trabalho está em ocupações altamente expostas. Essa exposição não se distribui de forma neutra: concentra-se entre trabalhadores de apoio administrativo, mulheres, brancos, jovens e indivíduos com maior escolaridade, padrões consistentes com o que a OIT observa em países de renda média-alta. A formalidade reforça esse recorte: embora a força de trabalho informal seja maior do que a formal, são os trabalhadores com vínculo formal que se concentram nas ocupações de alta exposição (14,8%, contra 6,7% dos informais). Esse ponto é central para a estratégia empírica da dissertação, pois indica que a corte mais sujeita aos efeitos da IA está justamente no mercado formal, onde o CAGED tem cobertura plena.

Na etapa empírica, segui a abordagem de [Brynjolfsson, Chandar e Chen \(2025\)](#), com um desenho de diferenças em diferenças aplicado ao CAGED, usando o lançamento do ChatGPT como evento e o índice da OIT como fonte de variação no tratamento. Os resultados não apontam um choque generalizado de emprego: no agregado nacional, as admissões, os desligamentos e os salários reais de admissão apresentam coeficientes negativos, porém pequenos e estatisticamente não significativos, e os testes de tendências paralelas são rejeitados para os fluxos, o que limita a interpretação causal. O sinal mais consistente está no salário de entrada, que fica abaixo do das ocupações não expostas, ainda que sem significância robusta. Os ajustes só ganham nitidez quando a análise se desloca para grupos específicos: a retração das admissões é mais forte entre mulheres e trabalhadores com ensino superior, e a queda dos desligamentos é o resultado mais recorrente, aparecendo entre trabalhadores negros, na faixa de 25 a 34 anos, no ensino superior e nas ocupações de renda intermediária. Como admissões e desligamentos recuam ao mesmo tempo, o padrão é compatível com menor movimentação dos fluxos, e não com destruição de vínculos. No conjunto, os achados sugerem, como hipótese, uma acomodação silenciosa do emprego formal nas ocupações mais expostas após o ChatGPT, mas o desenho não observa a adoção efetiva da IA nem o estoque de emprego, e boa parte das estimativas permanece exploratória.

Esta dissertação contribui para a literatura em três dimensões. A primeira é de mensuração: adapto o índice de exposição da OIT ao Brasil, construindo uma correspondência entre classificações ocupacionais internacionais e brasileiras. A segunda é distributiva: mostro quem está mais exposto à IA no mercado de trabalho brasileiro, considerando ocupações, setores, regiões e características sociodemográficas. A terceira é empírica: apresento evidência inicial, a partir dos microdados do CAGED, sobre a dinâmica das admissões, dos desligamentos e dos salários de entrada nas ocupações formais mais expostas após o lançamento do ChatGPT, com atenção às heterogeneidades por sexo, raça, idade, escolaridade e renda.

O restante do trabalho está organizado da seguinte forma. A Seção 2 introduz a teoria e a metodologia dos índices de exposição à IA e justifica a escolha do *ILO Global Index*. A Seção 3 descreve a construção da base analítica com a PNADc e apresenta os resultados descritivos sobre a distribuição da exposição no Brasil. A Seção 4 apresenta a estratégia empírica com o CAGED, detalhando a construção do painel ocupação-mês, o *crosswalk* entre a CBO e o índice da OIT, a especificação de diferenças em diferenças e o desenho das heterogeneidades. A Seção 5 reúne os resultados, começando pelo efeito médio nacional, passando pelas heterogeneidades por sexo, raça, idade, escolaridade e renda, e encerrando com os casos ocupacionais e as trajetórias por idade.

2 Mensuração da exposição ocupacional à IA

2.1 Definição e interpretação da exposição ocupacional

Antes de discutir como medir, é preciso definir o que está sendo medido. O debate público sobre mercado de trabalho mistura com frequência três coisas distintas, e tratá-las como sinônimos leva a interpretações equivocadas. Por isso, começo separando os conceitos e fixando uma definição explícita de exposição que será usada ao longo de todo o trabalho.

Nesta dissertação, defino *exposição ocupacional* como o potencial de uma ocupação ser afetada pela IA, dado o conjunto de tarefas que a compõem. Uma ocupação é mais exposta quando uma parcela relevante de suas tarefas pode ser automatizada ou complementada por modelos de IA. A exposição é, portanto, uma medida de potencial técnico, e não um diagnóstico do que já aconteceu no mercado.

É importante separar a exposição de outros dois conceitos com os quais ela costuma ser confundida. A *adoção efetiva* da tecnologia depende de empresas, trabalhadores, custos, infraestrutura digital, regulação, incentivos e da capacidade de reorganizar processos produtivos; uma ocupação pode ser altamente exposta e mesmo assim ter adoção baixa. Os *efeitos sobre emprego e salários*, por sua vez, só podem ser identificados empiricamente depois que a tecnologia começa a se difundir. Em resumo: exposição não é adoção, não é impacto causal e não é um indicador de substituição automática. Ela mede apenas o quanto as tarefas de uma ocupação são, em princípio, alcançáveis pela IA.

Feita essa delimitação, podemos explorar como índices de exposição ocupacional à IA são construídos.

2.2 Fundamentos conceituais: tarefas, automação e complementaridade

A mensuração da exposição se apoia em uma escolha conceitual bem estabelecida na economia do trabalho: a abordagem baseada em tarefas. Seu ponto de partida é o trabalho seminal de [Autor, Levy e Murnane \(2003\)](#), segundo o qual um emprego é, na prática, um conjunto de tarefas. Essa abordagem muda nossa perspectiva de maneira objetiva: novas tecnologias não impactam ocupações inteiras de forma homogênea, elas impactam as tarefas que constituem essas ocupações.

Um experimento com radiologistas ilustra bem esse ponto. Diagnósticos feitos por IA foram iguais ou tão precisos quanto os de dois terços dos médicos americanos ([Agarwal et al., 2023](#)). Mas o diagnóstico é apenas uma das muitas tarefas da profissão, que também envolve coordenação de equipe, comunicação com outros médicos e interação com pacientes. Os avanços da tecnologia não tornam o radiologista substituível justamente porque automatizam uma parte do trabalho, não o trabalho todo. Enxergar ocupações como conjuntos de tarefas permite uma leitura mais realista do que pode acontecer com cada profissão e com o mercado de trabalho.

Desse mesmo arcabouço vem uma segunda distinção essencial, também associada a Autor, que ajuda a sair de uma visão binária em que a IA simplesmente substitui trabalhadores. Para uma dada tarefa, há dois cenários possíveis:

- **Automação:** a IA executa a tarefa sozinha, com a mesma qualidade e em menos tempo. Um tradutor focado em documentos empresariais, por exemplo, pode ter parte relevante de seu trabalho automatizada.
- **Complementaridade:** um profissional usa a IA para executar a tarefa com mais qualidade ou eficiência. Um atendente de telefone pode usar a IA para buscar e formular respostas melhores em tempo real, tornando seu trabalho mais eficaz sem ser substituído.

Essa distinção é central para interpretar corretamente os índices: um grau alto de exposição não significa, necessariamente, automação. Uma ocupação muito exposta pode estar caminhando para a complementaridade, não para a extinção. É por isso que medir exposição é diferente de prever desemprego, e é também por isso que a forma como cada índice trata automação e complementaridade importa para o que o score efetivamente mede.

2.3 Índices de exposição à IA na literatura

A partir desse arcabouço de tarefas, grupos acadêmicos e centros de pesquisa passaram a construir *índices de exposição à IA*: medidas que avaliam o quanto cada tarefa de uma ocupação está exposta à IA e agregam essas avaliações em uma pontuação por ocupação. Apesar de metodologias distintas, esses índices compartilham uma estrutura comum: produzem um valor contínuo, tipicamente entre 0 e 1, e o associam a classificações ocupacionais padronizadas, o que permite integrá-los a pesquisas domiciliares e registros administrativos.

Analisar e comparar os índices de exposição já existentes foi uma parte fundamental deste trabalho: foi a partir dessa comparação que entendi qual deles estava metodologicamente mais avançado e qual tinha maior correspondência com os dados e o cenário brasileiro. Para isso, comparei quatro índices olhando para três pontos principais: em que base ocupacional cada um se apoia, como mede a exposição e o quanto se adapta ao contexto brasileiro.

O **GPT Exposure** ([Eloundou et al., 2023](#)), desenvolvido por OpenAI e Universidade da Pensilvânia, é o trabalho de referência do campo. Estruturado na O*NET/SOC americana, foi o primeiro a usar a própria IA para avaliar tarefas, validando a abordagem contra anotadores humanos (concordância superior a 80%). Sua classificação era

essencialmente categórica: perguntava se a IA reduziria em pelo menos 50% o tempo de uma tarefa, mantendo a qualidade.

O **GENOE** (Benítez; Parrado, 2024), do Banco Interamericano de Desenvolvimento, também se apoia na O*NET, mas alterou o prompt fornecido ao modelo: em vez de avaliar tarefas isoladas, oferece ao LLM o contexto completo da ocupação (nome, conjunto de tarefas e implicações sociais), permitindo uma avaliação mais holística. É essa abordagem que captura, por exemplo, a diferença entre um juiz e um analista de crédito, ambos analisam grandes volumes de informação, mas o peso ético do papel do juiz reduz sua exposição.

O **Anthropic Economic Index** (Appel *et al.*, 2026) parte de dados reais de uso dos modelos da Anthropic. Substitui a lógica binária por dimensões econômicas como a *autonomia* (o grau em que o usuário delega a decisão à máquina) e a *taxa de sucesso* da tarefa.

O **ILO Global Index** (Gmyrek *et al.*, 2025), da OIT, é o único estruturado na **ISCO-08**, a classificação ocupacional internacional da ONU, complementada pela taxonomia polonesa de seis dígitos. Sua classificação combina validação humana e LLMs em três camadas: 1.640 trabalhadores avaliaram tarefas de sua própria área, um painel de especialistas revisou um subconjunto para avaliar a viabilidade prática da automação, e os modelos GPT-4o e Gemini Flash 1.5 atuaram como desempate nos casos de divergência. Esse gabarito validado por humanos foi então usado para escalar a classificação às 3.265 tarefas da ISCO-08. Além disso, o índice não trabalha apenas com a média das tarefas de uma ocupação, mas incorpora também o desvio padrão como medida de variância, o que permite distinguir profissões que serão profundamente transformadas daquelas que tendem a ser preservadas ou extintas.

Tabela 2.1 — Comparação dos índices de exposição à IA

Índice	Base ocupacional	Como classifica a exposição	Principal vantagem	Principal limitação para o Brasil	Papel na dissertação
GPT Exposure (Eloundou <i>et al.</i> , 2023)	O*NET / SOC (EUA)	LLM avaliando tarefa a tarefa, validado contra humanos; critério categórico (redução de 50% do tempo)	Pioneirismo metodológico; validação humana inicial	Dados sintéticos, sem validação por profissionais. Taxonomia americana exige crosswalk adicional	Referência conceitual
GENOE (Benítez; Parrado, 2024)	O*NET / SOC (EUA)	LLM com contexto completo da ocupação (avaliação holística)	Sensível a barreiras sociais e institucionais	Dados sintéticos, sem validação por profissionais; base americana	Comparação
Anthropic Economic Index (Appel <i>et al.</i> , 2026)	Dados reais de uso e estruturação O*NET / SOC (EUA)	Uso efetivo dos modelos; dimensões de autonomia e taxa de sucesso	Mede uso real; distingue automação de complementariedade	Viés de amostragem (apenas usuários de modelos específicos); base americana	Comparação
ILO Global Index (Gmyrek <i>et al.</i> , 2025)	ISCO-08 (internacional)	Validação em três camadas (trabalhadores, especialistas e LLMs) escalada por LLM; média e desvio padrão das tarefas	Robustez metodológica e comparabilidade internacional via ISCO-08	Índice global; pode não captar especificidades brasileiras; exige crosswalk COD/CBO	Índice principal

2.4 Escolha do índice da OIT e adaptação às bases brasileiras

Esta dissertação adota o **ILO Global Index** (Gmyrek *et al.*, 2025) como medida principal de exposição ocupacional à inteligência artificial. A escolha se apoia em dois critérios: a compatibilidade do índice com as classificações ocupacionais brasileiras e a robustez metodológica da sua construção.

O índice da OIT é construído com base na **ISCO-08**, a classificação internacional de ocupações. Isso facilita sua aplicação ao Brasil porque as duas classificações ocupacionais usadas nesta dissertação se relacionam com a família ISCO. A PNAD Continua utiliza a **COD**, classificação do IBGE derivada da ISCO-08. Já o CAGED utiliza a **CBO 2002**, que não é idêntica à ISCO-08, mas foi construída tomando a **ISCO-88** como referência. Como existe uma tabela oficial de correspondência entre **ISCO-88** e **ISCO-08**, é possível construir uma ponte entre as famílias ocupacionais da CBO e o índice da OIT, ainda que com mais cautela do que no caso da PNAD. A forma como esse *crosswalk* foi construído será detalhada nas Seções 3 e 4.

O segundo critério é metodológico. O índice da OIT combina avaliação humana de tarefas com classificação assistida por modelos de linguagem e utiliza não apenas a média dos *scores* das tarefas de cada ocupação, mas também sua variabilidade. Essa escolha permite distinguir ocupações pouco expostas, ocupações potencialmente complementadas pela IA e ocupações mais profundamente transformadas.

2.5 Limitações da medida de exposição

Fechando a seção, vale delimitar com clareza o que o índice de exposição não mede. Essa delimitação protege o trabalho de interpretações exageradas e ajuda a ler corretamente os resultados das seções seguintes.

- **Não mede uso efetivo de IA nas firmas.** O índice capta o potencial técnico das tarefas, não a adoção real da tecnologia por empresas e trabalhadores, que depende de custos, infraestrutura, regulação e incentivos.
- **Não mede impacto causal.** Exposição é uma medida ex-ante de potencial; por si só, ela não indica o que de fato acontece com emprego e salários. Qualquer afirmação sobre efeitos exige um desenho empírico próprio, apresentado na Seção 4.
- **Não mede substituição automática.** Um grau alto de exposição é compatível tanto com automação quanto com complementaridade. O índice não distingue, no nível da ocupação, se a IA substituirá ou apenas auxiliará o trabalhador.
- **Depende de um crosswalk ocupacional.** A aplicação às bases brasileiras passa por uma correspondência entre a ISCO-08 e as classificações nacionais (COD e CBO), que não é perfeita e introduz erro de medida, mais relevante no CAGED.
- **É um índice global.** Por ser construído a partir de uma taxonomia internacional, o índice pode não capturar particularidades do conteúdo das tarefas no contexto brasileiro, como diferenças de organização do trabalho, informalidade e composição setorial.

Em conjunto, essas ressalvas reforçam a leitura proposta na dissertação: a exposição é um ponto de partida para descrever quem está mais sujeito a ter seu trabalho afetado pela inteligência artificial no Brasil e para orientar a investigação empírica, e não uma previsão de substituição ou um diagnóstico de impacto já consumado.

3 Análise Descritiva

Esta seção apresenta a análise descritiva da exposição do mercado de trabalho brasileiro à inteligência artificial. A base analítica e os principais resultados foram obtidos ao integrar os microdados da PNAD Contínua ao índice de exposição da OIT, o que permitiu produzir o conjunto de análises descritivas aqui reportados.

3.1 Base analítica e amostra

A base analítica desta etapa combina os microdados da PNAD Contínua do 3º trimestre de 2025, produzida pelo IBGE, ao **ILO Global Index** (Gmyrek *et al.*, 2025). Optei pelo 3º trimestre de 2025 por ser o período mais recente com microdados completos disponíveis no momento da análise, o que permite retratar a estrutura ocupacional brasileira já sob ampla difusão da inteligência artificial. Da pesquisa, selecionei 15 variáveis que cobrem características demográficas, ocupacionais, salariais e de jornada. As observações passaram por filtros conservadores: remoção de dados faltantes críticos, restrição à faixa etária de 18 a 65 anos e exclusão de códigos de ocupação inválidos. Ponderado pelo peso amostral V1028, o universo final representa 97,8 milhões de trabalhadores ocupados. Vale registrar que esta etapa é descritiva, não causal: o objetivo é caracterizar quem está exposto, e não estimar efeitos da IA sobre o emprego.

A ponte entre os dois conjuntos de dados é o *crosswalk* entre a COD, classificação da PNADc, e a ISCO-08, na qual o índice da OIT é construído. Como a seção anterior já discute a medida de exposição e a lógica desse *crosswalk*, aqui basta resumir a estratégia e reportar a cobertura. Como a COD deriva da ISCO-08 e compartilha a mesma estrutura hierárquica de quatro dígitos, a correspondência direta funciona para a grande maioria dos casos; nos casos sem *match* exato, adotei uma estratégia hierárquica de *fallback*, buscando correspondência a 3 e depois a 2 dígitos e atribuindo o score médio do subgrupo. Na prática, 97,9% das observações encontraram correspondência exata e a cobertura final ficou em 99,2%.

Três limitações devem ser registradas. Primeiro, a análise se apoia em um trimestre específico (3T/2025), o que oferece um retrato transversal, e não uma trajetória temporal. Segundo, a restrição etária de 18 a 65 anos deixa de fora trabalhadores nas pontas da distribuição de idade. Terceiro, apesar da cobertura elevada, o *crosswalk* COD-ISCO ainda comporta erros residuais de mapeamento.

A Tabela 3.1 sintetiza a ficha técnica da base analítica final, organizada em três blocos: as características da PNAD (fonte, universo e amostra), a qualidade do cruzamento COD-ISCO e as dimensões analíticas usadas adiante.

Tabela 3.1: Ficha técnica da base analítica final

Item	Valor
Fonte, universo e amostra	
Fonte	PNADc 3T/2025 (IBGE) + ILO WP140 (Gmyrek <i>et al.</i> , 2025)
Universo	População ocupada de 18 a 65 anos com código de ocupação válido
Observações na amostra	207.901
População representada	97,8 milhões
Peso amostral	V1028 (projeção populacional trimestral)
Cobertura ocupacional e qualidade do merge	
Ocupações ISCO-08	427
Ocupações COD com match	422 (de 428 presentes na PNAD)
Cobertura de score (% pop.)	99,2%
Match a 4 dígitos	97,9%
Match a 3 dígitos	1,3%
Sem classificação	0,8%
Dimensões analíticas	
Unidades federativas	27
Setores agregados (CNAE Dom. 2.0, seções A a T)	19
Salário mínimo de referência	R\$ 1.518 (Brasil, 2024)

3.2 Distribuição agregada da exposição à IA no Brasil

A exposição média ponderada do mercado de trabalho brasileiro à inteligência artificial é de 0,278. Mas a metodologia do ILO Global Index vai além da média simples: ela organiza as ocupações em gradientes de exposição. A formulação do gradiente cruza a nota média de exposição da profissão (μ) com a variabilidade de suas tarefas (σ). A lógica é direta: a exposição tende a ser maior quando uma profissão concentra tarefas de alta exposição e apresenta baixa variabilidade; quando a média é alta, mas há variedade de tarefas pouco expostas, a profissão tende a ser mais resiliente. Essa formulação também ajuda a distinguir os casos de complementaridade dos de automação.

Antes de ler a Tabela 3.2, convém fixar o que cada faixa significa. As ocupações "Não expostas" não cumprem nenhuma condição de exposição relevante; a "Exposição mínima" reúne casos residuais ou pontuais; os Gradientes 1 e 2 indicam exposição parcial, em que a IA tende a complementar o trabalho humano (*augmentation*); e os Gradientes 3 e 4 reúnem a chamada alta exposição, em que a tecnologia tende a transformar profundamente ou substituir tarefas.

A Tabela 3.2 apresenta a distribuição da população ocupada por gradiente de exposição.

Tabela 3.2: População ocupada por gradiente de exposição à IA

Categoria	Interpretação	População (milhões)	%
Não exposto	Ocupações sem exposição relevante	52,2	53,9
Exposição mínima	Exposição residual ou pontual	15,2	15,7
Gradiente 1	Exposição parcial; tarefas potencialmente complementadas pela IA	8,7	9,0
Gradiente 2	Exposição parcial mais intensa; complementação provável	10,0	10,3
Gradiente 3	Alta exposição; transformação profunda das tarefas	4,8	4,9
Gradiente 4	Exposição máxima; tarefas potencialmente substituíveis	5,0	5,1
Sem classificação	Score atribuído por agregação ISCO; gradiente não reportado pelo WP140	1,0	1,1


Nota: o agrupamento do ILO combina a média (μ) e o desvio padrão (σ) dos scores de tarefa. Exposição mínima: $\mu < 0,5$ e $\mu + \sigma > 0,4$. Gradiente 1: $\mu < 0,4$ e $\mu + \sigma \geq 0,5$. Gradiente 2: $0,4 \leq \mu < 0,5$ e $\mu + \sigma \geq 0,5$. Gradiente 3: $0,5 \leq \mu < 0,6$ e $\mu + \sigma$

$\geq 0,5$. Gradiente 4: $\mu \geq 0,6$ e $\mu - \sigma \geq 0,5$. "Sem classificação" reúne cerca de 1,1% da população, com score atribuído por agregação ISCO, nível em que o WP140 não reporta gradiente.

A leitura por gradiente é o resultado central desta seção. Mais da metade da força de trabalho brasileira (53,9%, ou 52,2 milhões) está em ocupações classificadas como "Não Expostas", predominantemente ocupações elementares, da agropecuária, da construção e da indústria de transformação tradicional. Outros 15,7% (15,2 milhões) estão em "Exposição Mínima". Os Gradientes 1 e 2, em que a OIT considera mais provável que a IA complemente o trabalho humano (*augmentation*), reúnem 9,0% e 10,3% da população, respectivamente. Já os Gradientes 3 e 4, em que a IA tende a transformar profundamente as tarefas ou substituí-las, somam 9,8 milhões de trabalhadores, ou 10,1% da força de trabalho ocupada.

A Figura 3.1 detalha o formato dessa distribuição por meio do histograma ponderado de scores, com a curva de densidade (KDE) sobreposta.


Figura 3.1: Distribuição da exposição à IA no Brasil



A figura evidencia que, para uma mesma faixa de score médio, podem coexistir diferentes gradientes; entre 0,2 e 0,4, em particular, a exposição da população é mais heterogênea.


A Figura 3.2 resume a mesma informação em termos de contingente populacional por gradiente.

Figura 3.2: População ocupada por gradiente de exposição à IA



Nota: percentuais calculados sobre ocupados classificáveis nos seis gradientes oficiais da OIT.

Figura 3.2: População ocupada por gradiente de exposição à IA




Nota: percentuais calculados sobre ocupados classificáveis nos seis gradientes oficiais da OIT.

A OIT estimou a proporção de trabalhadores com alta exposição à inteligência artificial (Gradientes 3 e 4) para diferentes grupos de países, o que permite uma comparação informativa com os dados encontrados neste estudo. A taxa de trabalhadores altamente expostos no Brasil (10,1%) fica ligeiramente acima da estimativa global da OIT (7,5%) e do padrão projetado para países de renda média-alta (7,0%). No entanto, a distância é expressiva quando comparamos o mercado brasileiro às economias de alta renda, em que a alta exposição atinge 17,3% da força de trabalho. Essa diferença reflete a estrutura ocupacional do país, caracterizada por um peso ainda expressivo de ocupações em setores de baixa exposição tecnológica, como a indústria de transformação tradicional e a agropecuária.

3.3 Ocupações mais expostas à IA

Como o índice de exposição é construído no nível ocupacional, o ponto de partida natural é identificar quais ocupações estão no topo da distribuição. A Figura 3.3 mostra a composição da população ocupada por faixa de score, segundo o grande grupo ocupacional.

Figura 3.3: Composição da população ocupada por faixa de score de exposição à IA, segundo o grande grupo ocupacional



A figura evidencia uma moda em torno de 0,12 a 0,18, formada por ocupações elementares, da indústria e da agropecuária, e uma cauda secundária por volta de 0,55 a 0,65, composta sobretudo por trabalhadores do apoio administrativo.

A Tabela 3.3 detalha as cinco ocupações em alta exposição com maior contingente de trabalhadores na PNADc. A seleção, portanto, não corresponde aos maiores scores médios absolutos, mas às ocupações dos Gradientes 3 e 4 que concentram mais trabalhadores. No Anexo 1.1 consta a tabela completa, com a média de exposição, o gradiente e o contingente estimado de cada ocupação segundo a COD.

Tabela 3.3: Top 5 ocupações em alta exposição com maior contingente de trabalhadores

COD	Ocupação (descrição ISCO-08)	Exposição média	Pop. (milhões)	Grande grupo
4110	Auxiliares de escritório em geral	0,60	3,75	Apoio administrativo
4226	Caixas, bilheteiros e atendentes em estabelecimentos	0,57	1,04	Apoio administrativo
2411	Contabilistas	0,51	0,59	Profissionais das ciências
4120	Secretários administrativos e executivos	0,58	0,50	Apoio administrativo
2431	Profissionais de marketing, propaganda e relações públicas	0,55	0,43	Profissionais das ciências

A leitura confirma um padrão comum às análises baseadas em índices de exposição: as ocupações mais expostas à IA são as chamadas *white collar*. Em termos econômicos, trata-se de funções administrativas e de escritório, centradas em tarefas rotineiras, textuais, contábeis e de atendimento, e em geral associadas a maior escolaridade. O ponto central é que a exposição é ocupacional, não setorial: ela acompanha o tipo de tarefa executada, e não o ramo de atividade da empresa. Por isso, a próxima subseção mostra onde esses trabalhadores estão distribuídos.

3.4 Distribuição setorial e regional dos trabalhadores em alta exposição

Identificadas as ocupações que puxam a exposição, resta mapear onde se encontram os trabalhadores em alta exposição. Convém lembrar, antes, que o trabalho *white collar* existe em praticamente todos os setores da economia: uma indústria tem contabilidade e um hospital tem equipe administrativa. Por isso, não se deve ler a distribuição setorial como se apenas alguns ramos fossem alcançados pela IA; todos os setores têm trabalhadores em ocupações potencialmente expostas, em maior ou menor grau.

A Tabela 3.4 apresenta a distribuição dos trabalhadores em alta exposição por setor, distinguindo duas dimensões: a intensidade da exposição, isto é, a proporção de trabalhadores em alta exposição dentro de cada setor, e o volume, ou seja, o número absoluto de trabalhadores nessa condição. Essa distinção é importante porque setores pequenos podem ter alta intensidade de exposição, enquanto setores grandes podem concentrar maior número de trabalhadores expostos.

Tabela 3.4: Exposição à IA por setor (CNAE-Domiciliar 2.0, IBGE)

Setor	Total (M)	% BR	Exposição Média	Alta (M)	Alta (%)
Finanças e Seguros	1.53	1.6	0.512	0.84	54.9
Informação e Comunicação	1.73	1.8	0.456	0.55	31.9
Serviços Profissionais	4.07	4.2	0.420	1.27	31.2
Atividades Imobiliárias	0.70	0.7	0.386	0.12	17.8
Administração Pública	4.27	4.5	0.352	1.12	26.3
Comércio	17.83	18.6	0.342	1.36	7.7
Artes e Cultura	1.10	1.1	0.316	0.10	9.4
Saúde	6.19	6.5	0.300	0.85	13.7
Serviços Administrativos	4.37	4.6	0.294	0.82	18.8
Utilidades	0.72	0.8	0.293	0.11	15.2
Educação	7.18	7.5	0.290	0.65	9.0
Transporte	5.72	6.0	0.280	0.46	8.0
Alojamento e Alimentação	5.09	5.3	0.266	0.23	4.4
Ind. Extrativa	0.59	0.6	0.262	0.04	6.4
Ind. Transformação	11.31	11.8	0.245	0.76	6.7
Outros Serviços	4.04	4.2	0.219	0.25	6.3

Sector	Total (M)	% BR	Exposição Média	Alta (M)	Alta (%)
Serviços Domésticos	5.30	5.5	0.160	0.00	0.0
Agropecuária	6.97	7.3	0.155	0.06	0.8
Construção	7.23	7.5	0.146	0.18	2.5

Nota: universo de ocupados classificáveis (cerca de 96 milhões, excluindo "Sem classificação"). Setores derivados das seções A a T da CNAE-Domiciliar 2.0 (IBGE), a partir da variável V4013. "Exposição Média" é a média ponderada do score contínuo de exposição (0 a 1); "Alta (M)" e "Alta (%)" referem-se aos trabalhadores em Gradientes 3 e 4.


A Tabela 3.4 evidencia que Finanças e Seguros lidera em intensidade de exposição, com 54,9% de seus trabalhadores em alta exposição (Gradientes 3 e 4). Quando mais da metade de um setor está no nível de maior exposição, isso é representativo de uma transformação em curso. Em termos absolutos, porém, Comércio concentram os maiores contingentes, somando aproximadamente 1.36 milhões de trabalhadores em alta exposição. A relevância, nesse caso, não está tanto na proporção interna de cada setor, mas no número de pessoas em ocupações de alta exposição, o que amplifica o potencial agregado sobre o mercado de trabalho. Assim, a exposição à IA não se restringe aos setores de tecnologia: ela aparece em ocupações administrativas e profissionais distribuídas por diferentes atividades econômicas.

A mesma capilaridade aparece na dimensão regional. Os 9,8 milhões de trabalhadores em alta exposição não são exclusivos de um setor, e tampouco se concentram em um único polo: espalham-se por todos os estados do país. A Figura 3.4 mapeia simultaneamente o volume absoluto e a proporção de trabalhadores em alta exposição em relação à força de trabalho de cada unidade federativa.

Figura 3.4: Alta exposição à IA por estado

Figura 3.4: Alta exposição à IA por estado

Cor: participação dos trabalhadores em Gradientes 3 e 4 dentro da força de trabalho classificável de cada UF.



São Paulo concentra o maior contingente em termos absolutos: 2,8 milhões de trabalhadores, o que representa cerca de 12% da força de trabalho paulista. Esse resultado é esperado, pois o estado abriga a maior economia do país, com a maior concentração de sedes corporativas e serviços financeiros. Outros estados, como a Bahia, apresentam proporções consideravelmente menores, reflexo de uma estrutura ocupacional com maior peso de setores agrícolas, industriais e de serviços de baixa exposição.

O caso mais ilustrativo é o Distrito Federal. Apesar de ter uma força de trabalho relativamente pequena em termos absolutos, o DF apresenta a maior proporção de trabalhadores em alta exposição entre todas as UF's, consequência direta do seu perfil ocupacional: capital do país, com altíssima concentração de servidores públicos, analistas, profissionais técnicos e funções administrativas ligadas à máquina pública federal. É o caso em que a proporção diz mais do que o número absoluto.

A leitura combinada dos dois indicadores, volume e proporção, revela um fenômeno relevante para a agenda de políticas públicas. Embora a alta exposição à IA não represente a maioria da força de trabalho em nenhum estado, sua distribuição capilar por todo o território nacional implica que os efeitos potenciais da tecnologia sobre o mercado de trabalho não se restringem a um polo econômico específico. Em estados onde a proporção de trabalhadores altamente expostos é maior, como o DF, o Rio de Janeiro e São Paulo, políticas de requalificação, proteção salarial e monitoramento do emprego formal podem ter impacto proporcionalmente mais significativo sobre a estabilidade do mercado de trabalho local.


3.5 Perfil sociodemográfico

Esta subseção caracteriza o perfil dos trabalhadores brasileiros mais expostos à IA. Como a exposição está concentrada em ocupações administrativas, técnicas e profissionais, ela não se distribui aleatoriamente entre os grupos sociais: decorre da posição dos trabalhadores na estrutura ocupacional. Os resultados mostram maior exposição entre trabalhadores mais escolarizados, mulheres, brancos, jovens e formais, além de concentração relevante nas faixas intermediárias de renda. Os recortes a seguir detalham esse padrão.

3.5.1 Análise por sexo

A Figura 3.5 compara a exposição de mulheres e homens.

Figura 3.5: Exposição à IA por sexo




A exposição média das mulheres (0,303) é 0,044 ponto maior do que a dos homens (0,259), uma diferença relativa de +17% sobre a média masculina. A leitura mais informativa, porém, não está na média, mas em como a população se distribui entre os níveis de exposição: 14,5% das mulheres ocupadas (6,1 milhões) estão em alta exposição (G3 e G4), contra 6,8% dos homens (3,6 milhões). Proporcionalmente, as mulheres são 2,2 vezes mais presentes na alta exposição do que os homens. O trabalho analítico realizado pela OIT no WP140 aponta no mesmo sentido: em países de alta renda, 41% do emprego feminino está exposto.

3.5.2 Análise por raça

A Figura 3.6 apresenta o recorte racial.

Figura 3.6: Exposição à IA por raça




O padrão racial é semelhante em magnitude, mas oposto à direção que se costuma esperar em análises de desigualdade: trabalhadores brancos têm exposição média de 0,305, contra 0,257 entre trabalhadores negros, definidos pela agregação de pretos e pardos conforme [Osório \(2003\)](#), uma diferença relativa de +19% sobre a média negra. Em alta exposição, 12,5% dos brancos (5,2 milhões) estão expostos, contra 8,4% dos negros (4,5 milhões): os brancos são 1,5 vez mais presentes na alta exposição, mesmo sendo um contingente 11,9 milhões menor na força de trabalho ocupada (41,5 ante 53,4 milhões). A interpretação econômica conecta-se diretamente ao que foi visto: as ocupações de alta exposição são, em sua maioria, *white collar* e, no Brasil, esse tipo de trabalho está historicamente associado a maior renda e escolaridade. O país carrega um legado de desigualdade racial, com uma estrutura de mercado de trabalho forjada em séculos de escravidão, que concentrou e ainda concentra grande parte da população negra em ocupações elementares, da construção, dos serviços domésticos e da indústria de transformação, setores de alto volume, baixa remuneração e baixa exposição à IA.

3.5.3 Análise por faixa etária

A Figura 3.7 descreve a exposição ao longo da idade.

Figura 3.7: Exposição à IA por faixa etária




A exposição decresce de forma monotônica com a idade, partindo de 0,304 na faixa de 18 a 24 anos e caindo até 0,252 na faixa de 55 a 59 anos, uma diferença de 0,056 ponto, equivalente a +22% para os mais jovens em relação aos mais velhos. O contraste é ainda mais expressivo no segmento de alta exposição: a faixa de 18 a 24 anos tem 3,2 vezes mais trabalhadores em alta exposição (16,2%) do que a de 55+ (5,9%). Os jovens estão mais expostos por uma razão estrutural: ingressam preferencialmente em ocupações de apoio administrativo, vendas e serviços qualificados, justamente as mais expostas. Esse achado tem peso analítico relevante para a Etapa 2 desta dissertação, em que avalio se essa coorte mais exposta sofreu efeitos diferenciados após o lançamento do ChatGPT, padrão já documentado por [Brynjolfsson, Chandar e Chen \(2025\)](#), nos Estados Unidos.

3.5.4 Análise por nível de escolaridade

O gradiente educacional é o mais forte de todos os recortes individuais. A Figura 3.8 mostra esse padrão.

Figura 3.8: Exposição à IA por nível de escolaridade




A exposição média sobe de 0,179 entre trabalhadores sem instrução ou com fundamental incompleto para 0,275 entre os com médio completo (+54% em relação ao piso), 0,359 entre os com superior incompleto (+102%) e 0,364 entre os com superior completo (+105%), uma variação que mais que dobra a exposição ao longo da distribuição educacional. A interpretação é direta: a escolaridade abre acesso a ocupações de escritório, profissionais e técnicas, e essas são as mais expostas à IA.

3.5.5 Análise por renda

A Figura 3.9 relaciona a exposição e a faixa de renda.

Figura 3.9: Exposição à IA por faixa de renda



O padrão central é que, embora a exposição média à IA aumente com a renda (de 0,237 na faixa até 1 salário mínimo para 0,365 em 5 ou mais), a **alta exposição** (Gradientes 3 e 4) não cresce indefinidamente: ela sobe de 7,6% na faixa mais baixa para cerca de 12,3% nas faixas intermediárias (1 a 3 salários mínimos) e depois **satura**, ficando praticamente estável mesmo entre os mais ricos. Esse resultado pede cautela na interpretação. Há uma leitura intuitiva, mas equivocada, de que seria a elite intelectual e financeira o grupo mais exposto à IA, afinal é ela que lida com as tarefas mais sofisticadas, digitais e baseadas em conhecimento. Os dados mostram outra direção. A OIT chega à mesma conclusão no WP140: o Gradiente 4, o de maior exposição, concentra-se sobretudo entre os trabalhadores de apoio administrativo, digitadores de dados, escriturários de contabilidade, secretários e caixas. São profissões com tarefas altamente estruturadas, centradas em dados e em linguagem rotineira, exatamente o que os modelos de linguagem fazem com facilidade. Acima desse patamar, a renda passa a refletir mais cargos de gestão e profissões liberais especializadas, que tendem a cair em exposição **moderada** (G1 e G2), não alta. O resultado é que a maior massa de trabalhadores em alta exposição está em salários de até 2 salários mínimos, cerca de dois terços do total, um segmento com menor capacidade de absorver choques. Para o Brasil, isso tem uma implicação direta: os eventuais efeitos distributivos da IA devem aparecer primeiro na classe baixa e média de escritório, e não no topo da pirâmide.


3.5.6 Análise por situação de formalidade

A Figura 3.10 fecha os recortes com a situação de formalidade, que serve de ponte para a etapa empírica.

Figura 3.10: Exposição à IA por situação de formalidade

Exposição à IA generativa por situação de formalidade

Decomposição da força de trabalho ocupada por formalidade — Brasil 3T/2025




Cor: % da categoria em cada nível de exposição. Texto: % dentro do segmento ($\geq 2,5\%$) e volume total da categoria entre colchetes.


Fonte: PNAD Contínua 3T/2025 (IBGE) e Índice Global de Exposição Ocupacional à IAG (Gmyrek et al. 2025, OIT WP140).

A exposição média dos trabalhadores formais (0,305) é 0,046 ponto maior do que a dos informais (0,258), uma diferença relativa de +18% em relação à média informal. Novamente, o contraste é mais nítido na alta exposição: 14,8% dos formais (6,1 milhões) estão em ocupações de alta exposição (G3 e G4), contra apenas 6,7% dos informais (3,6 milhões). Em termos proporcionais, os trabalhadores com vínculo formal são 2,2 vezes mais presentes na alta exposição do que os informais. Apesar de a força de trabalho informal ser 32% maior do que a formal (54,6 ante 41,3 milhões de ocupados), os formais respondem por 63% dos 9,8 milhões em alta exposição (6,1 milhões) e os informais por apenas 37% (3,6 milhões).

Figura 5.2.2.1 — Raça/cor — Admissões



Nota: perfis dinâmicos relativos a novembro de 2022; os diagnósticos nacionais de tendências prévias falham.



Nota: perfis dinâmicos relativos a novembro de 2022; os diagnósticos nacionais de tendências prévias falham.

A interpretação é estrutural. Os trabalhadores formais, predominantemente empregados CLT em escritórios e na administração pública, concentram-se justamente nas ocupações de alta exposição.

3.6 Síntese e implicações para a análise com CAGED

Esta análise descritiva permitiu três conjuntos de achados. Primeiro, a alta exposição à IA alcança cerca de 10,1% da força de trabalho ocupada (9,8 milhões de trabalhadores), patamar acima da média global estimada pela OIT, mas ainda distante das economias de alta renda. Segundo, essa exposição é ocupacional: concentra-se em ocupações administrativas, de apoio, contábeis e de atendimento, e se distribui por praticamente todos os setores e estados, com destaque de intensidade para Finanças e Seguros e de volume para Serviços Profissionais e Administração Pública. Terceiro, porque decorre da posição na estrutura ocupacional, a exposição aparece de forma desigual entre os grupos sociais, sendo maior entre trabalhadores mais escolarizados, mulheres, brancos, jovens, formais e das faixas intermediárias de renda.

Esses achados motivam diretamente a próxima etapa. A PNAD oferece um retrato transversal: mede a exposição e caracteriza o perfil dos trabalhadores, mas não acompanha a dinâmica do emprego ao longo do tempo. Para investigar se a exposição à IA se traduz em mudanças efetivas no mercado de trabalho, é preciso uma base longitudinal do emprego formal. Isso é o que vamos fazer na próxima seção.

4 Estratégia Empírica

4.1 Abordagem de diferenças em diferenças

Para a estratégia empírica, a principal referência foi a abordagem de diferenças em diferenças e de estudo de eventos aplicados à difusão da IA feita por [Brynjolfsson, Chandar e Chen \(2025\)](#). Esse estudo acompanhou o mercado de trabalho americano a partir dos registros de folha de pagamento da ADP, uma das maiores processadoras de folha dos Estados Unidos, que paga salários para mais de 25 milhões de trabalhadores. Como a empresa processa esses pagamentos mês a mês, os autores conseguem observar admissões, desligamentos e salários em altíssima frequência e quase em tempo real, montando um painel mensal de milhões de vínculos por firma. A unidade da estimação, porém, não é o vínculo: os autores agregam o emprego em células de firma por quintil de exposição por mês e estimam uma regressão de Poisson com efeitos fixos de firma por quintil e de firma por tempo (Brynjolfsson, Chandar e Chen, 2025, p. 15). Essa granularidade, combinada a esse desenho, permitiu detectar ajustes finos por ocupação e por idade logo após o lançamento do ChatGPT. O principal achado do estudo é que esse ajuste se concentrou na porta de entrada do mercado: os trabalhadores mais jovens, de 22 a 25 anos, em ocupações mais expostas, como desenvolvimento de software e atendimento ao cliente, apresentaram queda relativa de cerca de 16% no emprego, na especificação com

controles de firma e tempo da versão de 13 de novembro de 2025, enquanto o emprego dos trabalhadores mais velhos e experientes nas mesmas ocupações permaneceu estável ou até cresceu.

No Brasil, o equivalente mais próximo dessa base é o CAGED (Cadastro Geral de Empregados e Desempregados), estatística administrativa do Ministério do Trabalho e Emprego construída a partir de informações do eSocial, do CAGED e do Empregador Web. Desde janeiro de 2020, a maior parte das empresas cumpre a obrigação de informar admissões e desligamentos pelo eSocial, e os registros são consolidados mensalmente. Essa obrigatoriedade dá ao CAGED cobertura praticamente completa do mercado formal em frequência mensal, o que o torna adequado para acompanhar a porta de entrada e de saída do emprego, justamente a margem em que a literatura internacional tem encontrado os primeiros sinais de ajuste à IA. A adaptação ao Brasil, porém, exige duas ressalvas em relação ao artigo de referência. Primeiro, o CAGED observa fluxos formais de admissões e desligamentos, e não o estoque mensal de trabalhadores por firma. Segundo, a variação de exposição vem do índice da OIT aplicado à CBO, e não de quintis construídos sobre a classificação ocupacional americana. Por isso, o que se faz aqui é uma análise da dinâmica do emprego formal brasileiro em ocupações mais expostas, e não uma reprodução direta do painel firma-trabalhador do artigo de referência.

A escolha do CAGED sobre a PNAD Contínua, usada na Seção 3, decorre do que se quer medir. O objeto desta seção é a porta de entrada do emprego formal — admissões e salário de contratação — e é nessa margem que a literatura internacional tem encontrado os primeiros ajustes à IA. Três propriedades tornam o CAGED mais adequado. Primeiro, a **frequência**: o CAGED é mensal e a PNADc é trimestral, e um estudo de eventos centrado em novembro de 2022 precisa de resolução mensal para separar o antes do depois, ao passo que, com dados trimestrais, o trimestre do evento é simultaneamente pré e pós. Segundo, a **natureza do registro**: o CAGED é registro administrativo de declaração obrigatória, com cobertura praticamente completa do mercado formal, enquanto a PNADc é amostra domiciliar complexa, cuja precisão não se sustenta em recortes por ocupação de quatro dígitos, em que muitas células teriam poucas observações por trimestre. Terceiro, e mais importante, o **objeto observado**: a PNADc mede o estoque de ocupados e o CAGED mede o fluxo de admissões e desligamentos, e a hipótese testada aqui é sobre contratação — o estoque só se move depois que o fluxo se move.

A contrapartida é declarada e é séria: o CAGED observa apenas o mercado formal e não observa o estoque. Se a difusão da IA empurrar trabalhadores para a informalidade, esse deslocamento é invisível aqui. A Seção 3, baseada na PNADc, cumpre o papel complementar de caracterizar a estrutura ocupacional e a informalidade; as duas seções respondem a perguntas diferentes com a base adequada a cada uma.

O desenho não capta a adoção direta de IA dentro das firmas, pois o CAGED não informa se uma empresa usa ChatGPT ou ferramentas semelhantes. O que se estima é se ocupações mais expostas passaram a apresentar evolução diferencial após a difusão da tecnologia. O choque temporal vem da difusão pública da IA, e a intensidade do tratamento vem da exposição ocupacional medida pela OIT. O evento escolhido é o lançamento público do ChatGPT, em 30 de novembro de 2022, tratado como marco inicial da difusão dos LLMs (*Large Language Models*). Essa escolha dialoga com a literatura recente e é o evento usado no estudo de referência de [Brynjolfsson, Chandar e Chen \(2025\)](#).

A literatura recente documentou que estimadores de diferenças em diferenças com efeitos fixos de duas vias podem produzir ponderações negativas e estimativas viesadas quando as unidades são tratadas em **momentos diferentes** (Goodman-Bacon, 2021; Callaway e Sant'Anna, 2021; Sun e Abraham, 2021; de Chaisemartin e D'Haultfoeulle, 2020). Esse problema não se aplica a este desenho. Aqui a data de tratamento é única e comum a todas as ocupações expostas — o lançamento público do ChatGPT — e existe um grupo que nunca é tratado, as ocupações não expostas. Sem adoção escalonada não há comparações entre coortes tratadas em momentos distintos, que é a fonte das ponderações negativas. Nesse caso, o estimador de dois grupos e dois períodos com efeitos fixos é o estimador correto sob a hipótese de tendências paralelas, e os estimadores robustos a escalonamento seriam numericamente equivalentes a ele.

Registre-se ainda que a escolha de novembro de 2022 como referência do estudo de eventos não é idiossincrática. Humlum e Vestergaard (2025, p. 12, nota 8) observam que estudos de evento centrados nessa data se tornaram comuns na literatura e citam cinco trabalhos que a adotam.

4.2 Construção do painel ocupação-mês com CAGED e crosswalk CBO → OIT

Como vimos anteriormente, enquanto a PNAD utiliza a COD (Classificação de Ocupações para Pesquisas Domiciliares), a taxonomia usada no CAGED é a CBO (Classificação Brasileira de Ocupações). Por isso, a unidade de análise desta etapa é a ocupação CBO de quatro dígitos observada mês a mês. A partir dos microdados do CAGED, construo, para cada ocupação e período, medidas agregadas de admissões, desligamentos, saldo líquido e salários médios de admissão e desligamento.

O painel é construído a partir de uma única safra oficial do Novo CAGED, e a série de cada mês obedece à identidade $MOV + FOR - EXC$: as movimentações declaradas no prazo, mais as declarações fora do prazo, menos as exclusões. Todas as movimentações são reatribuídas ao **mês de competência do fato**, e não ao mês em que foram declaradas. O procedimento importa porque a incidência de declaração fora do prazo não é constante no tempo: usar apenas o arquivo de movimentações omitiria 8,6% dos registros de 2021 contra 1,3% dos de 2024, uma perda que cresce para trás e que se confundiria com tendência prévia. A série mensal assim reconstruída reproduz exatamente a série ajustada divulgada pelo PDET nos 65 meses, em admissões, desligamentos e saldo.

Três regras de tratamento completam a construção. Primeira, registros com salário fora do intervalo aberto entre zero e R\$ 1 milhão, idade fora da faixa de 14 a 90 anos, CBO inválida ou código de movimentação impossível são rejeitados antes da agregação — ao todo, 3.574.530 de 252.838.929 linhas, ou 1,4%. Segunda, salário e composição são tratados como **ausentes**, e não como zero, quando o fluxo correspondente é nulo: há 403 células sem nenhuma admissão e 355 sem nenhum desligamento, e preenchê-las com zero faria a winsorização produzir salários plausíveis onde não houve contratação alguma. Terceira, a winsorização é aplicada no nível do registro, nos percentis 1 e 99, dentro de cada célula de CBO de quatro dígitos por ano, igualmente ao salário de admissão e ao de desligamento.

Tabela 4.2.1 — Escopo do painel ocupação-mês

Indicador	Valor
Células CBO-mês no painel observado	39.742
Células CBO-mês na amostra principal	22.049
CBOs na amostra principal	341
CBOs tratadas / controle	75 / 266
Meses	65
Janela	2021-01 a 2026-05

Notas: o painel observado reúne todas as 630 famílias de CBO de quatro dígitos presentes na safra; a amostra principal retém apenas as 341 que entram no contraste entre expostas e não expostas. Os dois números são distintos e nomeados separadamente de propósito. Fonte: [results/reconciliation/painel_nacional_support.json](#) e [results/models/specification_ladder.csv](#).

A janela de análise começa em janeiro de 2021 por duas razões. Primeiro, o Novo CAGED teve início em janeiro de 2020, não havendo dados diretamente comparáveis para períodos anteriores. Segundo, optei por excluir o ano de 2020 porque ele coincide com a fase mais aguda da pandemia de Covid-19, marcada por fortes alterações nas admissões, nos desligamentos e nos salários. A inclusão desse período poderia fazer com que os efeitos excepcionais da pandemia fossem confundidos com as tendências anteriores à difusão do ChatGPT. Assim, o painel compreende o período entre janeiro de 2021 e maio de 2026, preservando 23 meses anteriores ao evento e 42 posteriores. A janela é assimétrica, com mais tempo depois do evento do que antes, o que é prática corrente nesta literatura: Klein Teeselink (2025, p. 11) trabalha com 15 meses de pré e 30 de pós.

O principal desafio metodológico é fazer a correspondência do CBO, usada nos registros administrativos brasileiros, com o índice da OIT, construído em ISCO-08. Para evitar uma correspondência ad hoc entre códigos numericamente parecidos, adotei uma ponte institucional em duas etapas. Primeiro, usei a tábua oficial do Ministério do Trabalho e Emprego que relaciona CBO 2002, CBO 94 e CIUO/ISCO-88. Em seguida, converti os códigos ISCO-88 para ISCO-08 por meio da tabela de correspondência da OIT. O caminho completo é, portanto: CBO 2002 → CBO94/CIUO88 via MTE → ISCO-08 via OIT → índice de exposição da OIT. A correspondência é mantida apenas quando existe uma ponte institucional identificável entre a família ocupacional brasileira e a classificação internacional.

As 193 CBOs sem correspondência válida são classificadas como *No score* e ficam fora da amostra principal, pois a ausência de score indica falta de correspondência oficial, não ausência de exposição. Essa perda não é aleatória, e convém declará-la: entre as ocupações sem score, o grande grupo 1 da CBO — membros superiores do poder público, dirigentes e gerentes — responde por 19,2% dos casos, contra 2,8% entre as classificadas, uma sobre-representação de cerca de sete vezes. Em sentido oposto, os grandes grupos 7 e 8, de trabalhadores da produção de bens e serviços industriais e de operadores de processos contínuos, caem de 25,9% e 11,7% entre as classificadas para 10,4% e 2,6% entre as perdidas. Como a gerência está entre os grupos de maior exposição na literatura, a perda tende a retirar da amostra ocupações de exposição alta, e portanto empurra as estimativas na direção conservadora. Como a relação entre CBO e ISCO é muitas-para-muitas, uma mesma CBO de quatro dígitos pode estar associada a mais de um destino ISCO-08. Nesses casos, reuni os destinos ISCO-08 com score disponível e calculei uma medida agregada de exposição para a CBO. A classificação final preserva a lógica do índice da OIT, combinando o nível médio de exposição e a dispersão das tarefas associadas à ocupação. Com isso, a atribuição de exposição não depende de um único

destino ocupacional, mas de uma média dos códigos internacionais associados àquela família CBO. Como mostra a Tabela 4.2.2, a classificação final organiza as CBOs em seis grupos.

Tabela 4.2.2 — Classificação das CBOs segundo o índice da OIT e definição de grupos de tratamento e controle.

Categoria OIT	CBOs	Match MTE	Tratamento	Controle	Excluído	Média score	SD pool
Exposed: Gradient 4	0	0					
Exposed: Gradient 3	31	31	✓			0,539	0,114
Exposed: Gradient 2	31	31	✓			0,452	0,121
Exposed: Gradient 1	13	13	✓			0,356	0,167
Minimal Exposure	95	95			✓	0,329	0,123
Not Exposed	266	266		✓		0,202	0,080
No score	193	0			✓		

Convém explicitar uma propriedade da regra de classificação: por combinar o score médio com a dispersão dos destinos ISCO, ela não é função monótona do score, de modo que ocupações com score parecido podem cair em lados opostos. As 75 tratadas cobrem a faixa de 0,280 a 0,593; as 95 de *Minimal Exposure*, de 0,220 a 0,410; e as 266 de controle, de 0,090 a 0,320. Na faixa de sobreposição entre 0,280 e 0,320 convivem 64 ocupações: 30 no controle, 31 excluídas como *Minimal Exposure* e 3 tratadas. A atenuante é quantitativa e vale registrar junto: 72 das 75 tratadas, ou 96%, têm score acima do máximo observado no grupo de controle. A faixa de ambiguidade é estreita, mas existe, e nenhuma leitura dos resultados deve tratar a fronteira como nítida.

Um ponto importante dessa classificação é que nenhuma CBO de quatro dígitos ficou no Gradiente 4, o de maior exposição, como mostra a Tabela 4.2.2. Isso é uma consequência direta do crosswalk: como uma mesma CBO costuma corresponder a vários códigos ISCO-08, a exposição atribuída à ocupação vem da agregação desses destinos. Essa média tende a diluir os picos de exposição, pois scores individualmente altos são atenuados ao serem combinados com destinos menos expostos. O resultado é que a classificação no nível da CBO dificilmente alcança o gradiente mais extremo e, na amostra observada do CAGED, o grupo mais forte fica vazio. A margem é pequena e pode ser quantificada: o maior score entre as 436 CBOs pontuadas é **0,5933**, e o limiar do Gradiente 4 é **0,60**. O gradiente está vazio por 0,0067 — por aritmética da agregação, portanto, e não por escolha de classificação.

Essa diluição é atenuada pela forma como o grupo de tratamento foi definido. Reuni os Gradientes 1, 2, 3 e 4 em um único grupo de ocupações expostas. Assim, uma ocupação cujo score foi diluído continua classificada como exposta, ainda que em um gradiente mais baixo do que teria sob uma correspondência perfeita. A contrapartida é que o crosswalk perde precisão dentro de cada gradiente: ele não sustenta, com segurança, análises que tratem os gradientes de forma isolada, comparando, por exemplo, o Gradiente 3 diretamente com o Gradiente 1. Por isso, a exposição é usada principalmente de forma binária, entre expostos e não expostos, e as análises por gradiente específico ficam em segundo plano.

Definido o grupo tratado, resta delimitar o controle. O modelo principal compara esse grupo tratado com as ocupações Not Exposed, que formam o controle estrito. O grupo Minimal Exposure fica fora do controle principal porque representa uma categoria intermediária: são ocupações com exposição média baixa, mas com alguma dispersão de tarefas potencialmente expostas. Incluí-las no controle poderia enfraquecer o contraste entre ocupações efetivamente não expostas e ocupações expostas. Por isso, Minimal Exposure entra apenas como especificação de robustez com controle ampliado.

Por fim, vale registrar a cobertura do painel. Entre as 630 famílias de CBO de quatro dígitos presentes no painel — as 629 classificadas mais a CBO 2414, que aparece apenas na safra nova e permanece sem score —, 436 receberam correspondência oficial e score de exposição, o que representa 69,2% das famílias e 70,7% das células ocupação-mês. Em termos de volume de movimentações, a cobertura é maior: essas ocupações concentram 92,3% dos fluxos observados no painel. A Tabela 4.2.3 resume essa cobertura por grupo de exposição.

Tabela 4.2.3: Cobertura do painel por grupo de exposição

Categoria	CBOs	% do total	Células CBO-mês	% das células	% dos fluxos
Exposed	75	11,9%	4.875	12,3%	21,7%
Not Exposed	266	42,2%	17.174	43,2%	41,2%

Categoria	CBOs	% do total	Células CBO-mês	% das células	% dos fluxos
Minimal Exposure	95	15,1%	6.033	15,2%	29,5%
No score	194	30,8%	11.660	29,3%	7,7%

Notas: as células são contadas sobre os 65 meses do painel observado. A amostra principal é a soma das linhas Exposed e Not Exposed, ou seja, 4.875 mais 17.174, igual a 22.049 células. A coluna de fluxos usa a soma de admissões e desligamentos. Fonte: [data/derived/painel_nacional.parquet](#).

4.3 Especificação econométrica e outcomes

Definidos o evento, o tratamento e o painel, resta especificar o modelo que estima o efeito da exposição à IA sobre o emprego formal e detalhar quais outcomes esse modelo procura explicar.

A especificação principal é um modelo de diferenças em diferenças com efeitos fixos de ocupação e de mês, que compara a evolução das ocupações expostas e não expostas antes e depois do lançamento do ChatGPT. Como os outcomes têm naturezas distintas, ela toma duas formas. Para os fluxos, que são contagens com zeros, a estimação é por pseudo-máxima verossimilhança de Poisson sobre a contagem em nível:

$$E[Y_{c,t} | \cdot] = \exp(\beta(\text{Exposta}_c \times \text{Pós}_t) + \alpha_c + \delta_t)$$

Para o salário real de admissão e o saldo líquido, a especificação é linear:

$$Y_{c,t} = \beta(\text{Exposta}_c \times \text{Pós}_t) + \alpha_c + \delta_t + \varepsilon_{c,t}$$

Cada termo do modelo cumpre um papel específico:

- $Y_{c,t}$ é o outcome da ocupação c , a CBO de quatro dígitos, no mês t .
- $\text{Exposta}_c \times \text{Pós}_t$ é a interação que identifica o efeito: assume valor 1 para ocupações expostas, isto é, dos gradientes 1 a 4 da OIT, a partir de dezembro de 2022, e 0 nos demais casos.
- β é o coeficiente de interesse, que mede a mudança diferencial das ocupações expostas em relação às não expostas depois do choque. Na especificação linear ele é lido em logaritmo; na PPML ele é uma **semi-elasticidade da média condicional em nível**, de modo que a variação percentual implícita é $100 \times (e^\beta - 1)$ e não uma elasticidade log-log.
- α_c são os efeitos fixos de ocupação, que absorvem diferenças estruturais e constantes entre CBOs, como nível médio de salário e intensidade de contratação.
- δ_t são os efeitos fixos de mês, que absorvem choques comuns a todas as ocupações em um dado mês, como sazonalidade, inflação agregada e ciclo econômico.
- $\varepsilon_{c,t}$ é o termo de erro. Os erros-padrão são agrupados no nível da CBO de quatro dígitos, com 341 grupos, e a inferência usa a distribuição t com $G - 1$ graus de liberdade.

Podemos interpretar: como α_c remove o que cada ocupação tem de fixo e δ_t remove o que é comum a cada mês, β capta apenas o que muda de forma diferente nas ocupações expostas justamente após o ChatGPT.

Além do modelo estático, estimo estudos de eventos que substituem a interação única $\text{Exposta} \times \text{Pós}$ por interações entre o tratamento e cada mês relativo ao evento:

$$E[Y_{c,t} | \cdot] = \exp\left(\sum_{k=-23, k \neq -1}^{+41} \beta_k \mathbf{1}[t - t^* = k] \times \text{Exposta}_c + \alpha_c + \delta_t\right)$$

com t^* igual a dezembro de 2022 e o mês de referência $k = -1$, novembro de 2022, omitido. Não há agrupamento de caudas: cada coeficiente corresponde a um mês. A versão linear substitui a exponencial pela forma aditiva, com o mesmo conjunto de interações. Esse desenho tem duas funções: mostrar como o efeito evolui ao longo do tempo e testar se as ocupações tratadas já seguiam trajetória diferente antes do ChatGPT.

Uma decisão adicional diz respeito aos controles de composição dos admitidos — idade média, participação feminina, participação com ensino superior e composição racial. **Eles não entram na especificação principal.** A razão é que são variáveis pós-tratamento: se a difusão da IA muda quem é contratado, controlá-las remove justamente parte do efeito que se quer medir, e o coeficiente deixa de responder à pergunta de interesse. Elas passam a ser reportadas de duas

formas subordinadas: como especificação descritiva, para caracterizar o que mudou na composição, e como robustez, na forma de composição medida no pré-tratamento interagida com o pós, que não sofre desse problema.

A escolha do PPML para as contagens também merece justificativa. As contagens de admissões e desligamentos contêm zeros, e a log-linearização de variáveis com zeros exige transformações cujo coeficiente não recupera a elasticidade de interesse. Silva e Tenreiro (2006) mostram que a estimação log-linear é viesada sob heterocedasticidade, e Chen e Roth (2024) documentam os problemas de $\log(1 + y)$ na presença de zeros. A pseudo-máxima verossimilhança de Poisson estima a média condicional em nível e acomoda os zeros diretamente. Essa é também a escolha de Brynjolfsson, Chandar e Chen (2025), que estimam regressão de Poisson pelo mesmo motivo. Os modelos de mínimos quadrados sobre $\log(1 + y)$ permanecem reportados como estimador secundário.

O mesmo modelo é aplicado a diferentes outcomes, porque a difusão da IA pode atingir o mercado formal por várias margens: reduzir contratações, mudar a composição dos desligamentos, afetar salários de entrada ou alterar o saldo líquido de vínculos. A Tabela 4.3.1 resume os outcomes principais, sua definição e a transformação usada na estimação.

Tabela 4.3.1: Outcomes da análise

Grupo	Outcome	Definição	Transformação
Fluxos	Admissões (PPML, nível)	Número de admissões formais na ocupação-mês	PPML sobre a contagem em nível; semi-elasticidade
Fluxos	Desligamentos (PPML, nível)	Número de desligamentos formais na ocupação-mês	PPML sobre a contagem em nível; semi-elasticidade
Fluxos	Fluxo bruto (PPML, nível)	Admissões mais desligamentos na ocupação-mês	PPML sobre a contagem em nível; semi-elasticidade
Salários	Salário real de admissão (log)	Salário médio de admissão deflacionado pelo IPCA	log; MQO. Diferença aproximada em proporção
Saldo	Saldo líquido (asinh)	Admissões menos desligamentos na ocupação-mês	asinh; MQO. Não interpretar como percentual

A escolha das transformações segue a natureza de cada outcome. Os três fluxos são contagens com zeros e entram no PPML em nível, pelas razões já expostas; seus coeficientes são semi-elasticidades e não devem ser lidos como elasticidades log-log. Os salários são deflacionados pelo IPCA para isolar variação real e entram em logaritmo. O saldo líquido usa asinh porque a medida pode ser negativa ou zero, e essa transformação preserva o sinal e permite estimar em toda a amostra; seu coeficiente, porém, não tem leitura percentual direta.

Por fim, a análise de heterogeneidade emprega uma diferença tripla, em que o painel passa a ser indexado também por subgrupo sociodemográfico g :

$$Y_{c,g,t} = \beta_{DDD} (\text{Pós}_t \times \text{Exposta}_c \times \text{Grupo}_g) + \gamma_1(\text{Pós} \times \text{Exposta}) + \gamma_2(\text{Pós} \times \text{Grupo}) + \gamma_3(\text{Exposta} \times \text{Grupo}) + \epsilon$$

Todos os termos de ordem inferior entram explicitamente. Vale distinguir com clareza os dois estimadores que aparecem na Seção 5, porque é fácil confundi-los. O **DiD dentro do grupo** responde à pergunta "entre as mulheres, as ocupações expostas divergiram das não expostas?" e é o que aparece nas tabelas do corpo do texto. O **DDD**, β_{DDD} , responde à pergunta "essa divergência é diferente da observada entre os homens?" e é o que aparece no Apêndice A. O primeiro capta o efeito nacional inteiro e por isso reaparece com sinal semelhante em quase todo grupo; apenas o segundo testa heterogeneidade.

4.4 Heterogeneidade e mecanismos

A literatura internacional sugere que os efeitos da IA generativa podem aparecer primeiro em trabalhadores no início da carreira. Brynjolfsson, Chandar e Chen (2025) mostram que, nos Estados Unidos, a queda relativa de emprego em ocupações expostas é mais intensa entre trabalhadores de 22 a 25 anos. A interpretação é que trabalhadores jovens dependem mais de conhecimento codificado, adquirido na educação formal, enquanto trabalhadores mais experientes acumulam conhecimento tácito e específico da firma. Se a IA substitui parte desse conhecimento codificado, os jovens podem ser mais vulneráveis. Agrupei idade conforme aplicado na PNAD, para ajudar na interpretação e comparação dos resultados da seção 3, mas também adotei as faixas etárias inspiradas no artigo de referência: 22-25, 26-30, 31-34, 35-40, 41-49 e 50 anos ou mais. Para dialogar com essa hipótese, essas faixas ajudam a separar o início da carreira de estágios mais avançados da trajetória profissional.

Na Seção 3, vimos que alguns perfis sociodemográficos, como mulheres e pessoas com alta escolaridade, estão mais expostos. Por esse motivo, estimo heterogeneidades por idade, sexo, raça/cor, escolaridade e renda. Nos exercícios

que cruzam perfis sociodemográficos e grupos ocupacionais, a heterogeneidade é estimada por grupo e por um modelo de diferenças-em-diferenças triplas (DDD). O coeficiente de interesse interage o período posterior ao lançamento do ChatGPT, o indicador de pertencimento ao grupo ocupacional tratado e o indicador do perfil analisado. Assim, ele mede se a mudança pós-ChatGPT no grupo tratado, relativamente às ocupações não expostas, difere entre o perfil em questão e seu complemento.

Esses exercícios envolvem um número grande de contrastes, e a 5% nominais alguns resultados significativos são esperados por acaso. Por isso adoto o procedimento de Benjamini e Hochberg (1995), que controla a taxa de falsas descobertas, aplicado sobre famílias declaradas **antes** da estimação:

Família	Conteúdo	Testes
A	DDD sobre as 20 partições originais, em 5 outcomes	100
B	DDD sobre as partições alternativas: faixas etárias da PNAD e agregado Negra	30
C	DiD dentro do grupo, nas 26 partições, em 5 outcomes	130

As famílias A e B são mantidas separadas porque as partições alternativas são reexpressões de dimensões já contidas em A — testar a faixa de 18 a 24 anos e testar a de 22 a 25 não são hipóteses independentes — e contá-las numa família única inflaria o denominador sem ganho informacional. Cada tabela da Seção 5 e do Apêndice A declara a que família pertence e qual o tamanho dela. O ajuste tem efeito material: na Família A, 34 dos 100 contrastes são nominalmente significativos a 5% e 21 sobrevivem à correção; na Família B, 6 de 30 e 4 sobrevivem; na Família C, 54 de 130 e 40 sobrevivem.

Também construí seis casos ocupacionais para investigar mecanismos: desenvolvedores de software, atendimento ao cliente, gerentes de marketing e vendas, supervisores de produção, estoquistas e repositores e auxiliares de saúde e cuidado. Os casos foram definidos semanticamente a partir das descrições oficiais das CBOs de seis dígitos, congelados antes da inspeção dos resultados e reúnem 76 códigos sem sobreposição. A composição segundo a OIT é usada posteriormente para interpretar os casos, não para selecioná-los por palavras-chave.

4.5 Validações e falsificações

As validações descritas a seguir foram definidas como regras de parada **antes** da estimação: um resultado que falhasse no placebo temporal seria reportado como falha, e não reinterpretado. Esta subseção declara o desenho de cada exercício; os números aparecem na Seção 5, e o conjunto completo, no pacote de replicação.

1. **Escala de especificações.** Sete degraus pré-registrados: sem controles, composição pré-tratamento interagida com o pós, composição contemporânea, *Minimal Exposure* incorporada ao controle, exposição contínua padronizada, amostra restrita ao período a partir de 2022 e amostra truncada em dezembro de 2025.
2. **Placebo temporal.** Um evento falso é datado em dezembro de 2021 e estimado apenas dentro do pré-período verdadeiro, descartando-se todo o período posterior ao ChatGPT. É o mesmo procedimento adotado por Teutloff *et al.* (2025, p. 12).
3. **Placebo de grupo.** Quinhentas reatribuições aleatórias do rótulo de tratamento, preservando o desenho de 75 ocupações tratadas entre 341, para situar o coeficiente observado na distribuição do que se obteria por acaso.
4. **Variantes de tratamento.** Quatro regras de classificação pré-registradas, que alteram o modo de combinar o score médio e a dispersão dos destinos ISCO.
5. **Medidas alternativas de exposição.** A safra de 2023 do índice da OIT, um consenso construído com GPT-4o e Gemini, e o índice de exposição da Anthropic.
6. **Sensibilidade a tendências prévias.** O procedimento de Rambachan e Roth (2023), nas restrições de magnitudes relativas e de suavidade, que substitui o teste binário de tendências paralelas por uma pergunta sobre quanta violação o resultado suporta.
7. **Nível setorial.** Efeitos fixos de seção da CNAE por mês, tratados como especificação co-principal e não como robustez subordinada, conforme a Tabela 5.1.1.
8. **Influência ocupacional.** Um jackknife que remove cada uma das 75 ocupações tratadas, uma de cada vez, para verificar se o resultado depende de poucas ocupações grandes.

Dois exercícios foram encerrados sem resultado a reportar, e vale declará-lo. A heterogeneidade por porte do estabelecimento foi estimada em cinquenta modelos e não produziu nenhuma rejeição após o ajuste de multiplicidade. O contraste entre setor público e privado não foi executado, porque os campos oficiais do CAGED codificam a forma

de registro do vínculo, e não a propriedade do empregador, de modo que o contraste pretendido não é identificável na base.

Cabe ainda justificar por escrito uma decisão de desenho que não é neutra: a exclusão das 95 CBOs de *Minimal Exposure* do grupo de controle. O argumento é de desenho, e não de resultado. Essas ocupações situam-se, na escala de exposição, entre as tratadas e as de controle, e incorporá-las ao contrafactual significaria comparar ocupações expostas com um controle parcialmente exposto, atenuando por construção o contraste que se quer medir. O degrau correspondente da escada de especificações reporta o que muda quando essa escolha é invertida.

5 Resultados

5.1 Resultados médios nacionais

A Tabela 5.1 apresenta as estimativas médias nacionais do modelo de diferenças em diferenças, comparando ocupações expostas à IA (gradientes da OIT) às não expostas após o lançamento do ChatGPT. Os coeficientes medem a variação relativa das ocupações expostas.

Tabela 5.1: Resultados médios nacionais

Resultado	Estimador	Coeficiente	EP	IC 95%	p	Pretrend	N
Admissões (nível)	PPML	-0,0538	0,0386	[-0,1296; 0,0221]	0,164	fail	22.049
Desligamentos (nível)	PPML	-0,0420	0,0347	[-0,1103; 0,0262]	0,227	fail	22.049
Salário real de admissão (log)	OLS	-0,0507	0,0103	[-0,0711; -0,0304]	< 0,001	fail	22.012
Saldo líquido (asinh)	OLS	-0,5513	0,3783	[-1,2954; 0,1929]	0,146	fail	22.049

Notas: especificação principal @1_no_controls, com efeitos fixos de CBO de quatro dígitos e de mês. Erros-padrão clusterizados por CBO de quatro dígitos, 341 clusters. Admissões e desligamentos são estimados por PPML em nível, e o coeficiente lê-se como semi-elasticidade; salário e saldo são estimados por MQO sobre o logaritmo e sobre o arco-seno hiperbólico, respectivamente. Não há estrelas de significância: os quatro pretrends falham e a tabela não sustenta leitura causal. O tratamento compara as CBOs expostas segundo os gradientes da OIT às CBOs classificadas como Not Exposed. Fonte: results/models/specification_ladder.csv.

Os quatro coeficientes têm sinal negativo, mas apenas um é estatisticamente significativo. As reduções aproximadas são de 5,4% nas admissões, 4,2% nos desligamentos e 5,1% no salário real de admissão, e o saldo líquido, medido em arco-seno hiperbólico, também é negativo. O salário é o único que rejeita a hipótese nula, e com folga: o intervalo de 95% vai de -7,1% a -3,0% e o p-valor é inferior a 0,001. Para admissões, desligamentos e saldo, as estimativas pontuais são numericamente não desprezíveis, mas os intervalos incluem zero por larga margem; como não foi definido um limiar ex ante de relevância econômica, elas não devem ser classificadas como economicamente relevantes.


A restrição à leitura causal, porém, vale para os quatro resultados sem hierarquia entre eles: o teste de tendências paralelas é rejeitado em todos. O diagnóstico foi estendido a cinco especificações alternativas — amostra restrita ao período a partir de 2022, agregação em nível setorial, tratamento medido como exposição contínua, *Minimal Exposure* como grupo de controle e cobertura salarial completa — e nenhuma das 51 células examinadas passa no teste. Não há, portanto, resultado neste bloco cuja identificação esteja assegurada pelo diagnóstico padrão. Como admissões e desligamentos caem simultaneamente, o padrão é compatível com menor movimentação dos fluxos; entretanto, como o modelo não observa o estoque de emprego, ele não permite concluir se houve ou não destruição líquida de vínculos.

A rejeição das tendências paralelas não é um resultado anômalo: é o que se espera de dois blocos ocupacionais com perfis cíclicos tão distintos. No período anterior ao evento, o grupo de controle apresenta desvio-padrão de crescimento mensal de 14,0%, contra 8,3% do grupo tratado, e amplitude sazonal de 44,7%, contra 27,3% — ou seja, o controle é 68% mais volátil e 64% mais sazonal que o tratado. As maiores ocupações de controle são manuais e de serviços, como manutenção de edificações e alimentadores de linha de produção, e respondem ao ciclo e à sazonalidade de forma sistematicamente diferente das ocupações administrativas e profissionais que concentram o grupo tratado. O desenho de exposição ocupacional herda essa diferença estrutural, e nenhuma das especificações testadas, inclusive as que incluem efeitos fixos de setor por mês, a elimina.

O diferencial salarial exige ainda uma qualificação. Cerca de um quarto dele decorre da mudança na composição educacional dos contratados: a participação de admitidos com ensino superior cai 2,7 pontos percentuais a mais no grupo exposto, e dois métodos independentes de decomposição atribuem entre 23% e 29% do diferencial a esse canal. Dentro de faixas de escolaridade comparáveis, o diferencial permanece entre 3,6% e 3,9%. Ele não decorre de composição de idade, sexo ou raça — dentro de cada uma dessas dimensões o diferencial é praticamente idêntico ao agregado — nem de jornada, já que o diferencial de salário-hora, de 6,95%, é maior que o mensal.

A Figura 5.1 apresenta os coeficientes mensais dos event studies (painéis superiores, com intervalos de confiança de 95%) e as trajetórias normalizadas pela média pré-tratamento (painéis inferiores, descritivos).

Figura 5.1: Resultados nacionais: event studies e trajetórias



O padrão mais consistente está no salário real de admissão: no pós-tratamento os coeficientes são sistematicamente negativos, com os salários de entrada das ocupações expostas abaixo dos das não expostas, e a estimativa média é precisa. O teste de tendências paralelas, porém, também é rejeitado aqui, de modo que a leitura causal permanece condicionada. Cabe uma observação sobre como ler os painéis: o event study normaliza cada mês contra novembro de 2022, ao passo que a tabela compara o pós-tratamento à média de todo o pré-período. Como os coeficientes pré do salário se situam em média em +0,037, a queda de 5,1% reportada na tabela corresponde a uma distância maior do que sugere a leitura dos painéis contra o zero.

O contrato congelado declara duas especificações co-principais, e não uma. O nível 1 compara ocupações expostas e não expostas em toda a economia; o nível 2 acrescenta efeitos fixos de seção da CNAE por mês, comparando ocupações dentro do mesmo setor no mesmo mês e absorvendo choques setoriais comuns. As duas respondem a perguntas diferentes, e a diferença entre elas é informativa.

Tabela 5.1.1: Controle setorial — especificações co-principais

Resultado	Nível 1 coef.	EP	p	Nível 2 coef.	EP	p	Diferenç N1
Admissões (nível)	-0,0538	0,0386	0,164	-0,0751	0,0356	0,036	-0,0213
Desligamentos (nível)	-0,0420	0,0347	0,227	-0,0664	0,0348	0,057	-0,0244
Fluxo bruto (nível)	-0,0481	0,0353	0,174	-0,0707	0,0343	0,040	-0,0226

Resultado	Nível 1 coef.	EP	p	Nível 2 coef.	EP	p	Diferença N1
Salário real de admissão (log)	-0,0507	0,0103	< 0,001	-0,0356	0,0064	< 0,001	0,0151
Saldo líquido (asinh)	-0,5513	0,3783	0,146	-0,1395	0,0734	0,058	0,4118

Notas: fluxo bruto é a soma de admissões e desligamentos. Nível 1: 22.049 células, 22.012 no salário, 341 clusters. Nível 2: de 804.574 a 804.735 células, 682.889 no salário, 341 clusters. Erros-padrão clusterizados por CBO de quatro dígitos nas duas especificações. Os dez pretrends falham, com $p < 0,001$ em todos, e por isso não há estrelas de significância. O nível 3 fica fora das colunas principais por ser diagnóstico de suporte. Fonte:

[results/tables/table_5_1_1_sector_control.md](#).

Nos fluxos, o controle setorial torna os coeficientes maiores em módulo e mais precisos: admissões passam de -0,0538, com $p = 0,164$, para -0,0751, com $p = 0,036$, e o fluxo bruto passa de -0,0481, com $p = 0,174$, para -0,0707, com $p = 0,040$. No salário ocorre o oposto: o diferencial cai de 5,1% para 3,6%, o que indica que cerca de três décimos dele são diferenças entre setores, e não entre ocupações dentro do mesmo setor — um canal distinto da composição educacional discutida acima, e que se soma a ela. O saldo líquido encolhe de -0,5513 para -0,1395.

Isso não altera a conclusão da subseção, por duas razões. Primeiro, os pretrends do nível 2 também falham nos cinco resultados, de modo que o ganho de precisão nos fluxos não vem acompanhado de ganho de identificação: a significância a 5% das admissões sob o nível 2 não pode ser lida como efeito causal. Segundo, o nível 2 não substitui o nível 1; ele informa quanto do diferencial é entre ocupações e quanto é entre setores, e é essa decomposição, e não a significância isolada, que o quadro acrescenta.

Esse quadro é coerente com a fronteira recente da literatura empírica sobre IA e emprego. [Brynjolfsson, Chandar e Chen \(2025\)](#), principal referência desta seção, também não encontram diferenças significativas no emprego agregado entre ocupações mais e menos expostas e enfrentam o mesmo problema de tendências paralelas: ocupações altamente expostas foram atingidas de forma distinta pela pandemia de Covid-19, o que contamina a linha de base anterior ao ChatGPT. A literatura recente encontra efeitos agregados pequenos ou nulos em alguns desenhos de curto prazo, mas também resultados negativos em subgrupos, firmas e ocupações; portanto, o padrão ainda não deve ser chamado de consolidado. [Humlum e Vestergaard \(2025\)](#), com dados administrativos da Dinamarca, reportam efeitos nulos e precisos sobre ganhos e horas mesmo dois anos após o ChatGPT; análises com a Current Population Survey dos Estados Unidos ([Chandar, 2025](#)) não identificam diferenças sistemáticas entre ocupações expostas e não expostas; e [Aldasoro et al. \(2026\)](#), com mais de 12 mil firmas não financeiras da União Europeia e dos Estados Unidos, associam a adoção de IA a um aumento de 4% na produtividade do trabalho, sem efeito adverso sobre o emprego no nível da firma no curto prazo. A leitura de que os sinais negativos simultâneos em admissões e desligamentos refletem menor rotatividade, e não destruição de vínculos, também encontra respaldo direto: [Hosseini Maasoum e Lichtinger \(2025\)](#) mostram que a contração do emprego em firmas que adotam IA vem sobretudo da desaceleração das contratações, acompanhada de queda nos desligamentos, e [Klein Teeselink \(2025\)](#), no Reino Unido, documenta reduções tanto no emprego quanto nas novas vagas; o artigo descreve a queda das vagas como gradual e com cronologia semelhante à do estoque, não como anterior a qualquer ajuste no emprego.

Em resumo, não há efeito médio nacional robusto nos fluxos: admissões, desligamentos e saldo são imprecisos e violam as tendências paralelas. O salário real de admissão é a exceção quanto à precisão — uma redução de 5,1%, estável nos quatro horizontes longos examinados, com coeficientes de -0,0514, -0,0507, -0,0481 e -0,0548, todos rejeitando a 5% —, mas partilha da mesma violação de tendências paralelas e, por isso, não pode ser lido como efeito causal estabelecido. Um placebo temporal datado em dezembro de 2021, quando o ChatGPT ainda não existia, produz -0,0198 no salário com $p = 0,081$: passa no critério de 5%, mas recupera 39% do coeficiente principal, o que reforça a cautela. O quadro dos fluxos acompanha o que a literatura internacional tem encontrado: no período e nas amostras examinadas, vários estudos encontram efeitos agregados pequenos ou nulos, com heterogeneidade e incerteza; isso não permite concluir que a IA não produza efeitos futuros ou concentrados em subgrupos. A própria literatura sugere por que a média nacional se aproxima de zero, pois o efeito é fortemente assimétrico entre grupos. É essa assimetria, com efeitos concentrados na porta de entrada do mercado, que motiva deslocar a análise do agregado nacional para os grupos sociodemográficos, objeto da próxima subseção.

5.2 Heterogeneidades demográficas

5.2.1 Efeitos por Sexo

A Tabela 5.2.1 apresenta os efeitos por sexo. As células reportam o DiD estimado **dentro da amostra de cada grupo**; a diferença formal entre homens e mulheres é testada pelo modelo DDD, reportado no Apêndice A. A distinção é essencial para a leitura: o primeiro mede se, entre as mulheres, as ocupações expostas divergiram das não expostas; o segundo, se essa divergência difere da observada entre os homens.

Tabela 5.2.1: Resultados por sexo

Grupo	Resultado	DiD no grupo	EP	p BH	Pretrend	Suporte
Homens	Admissões (PPML, nível)	-0,0779**	0,0272	0,019	fail	adequate
Homens	Desligamentos (PPML, nível)	-0,0635**	0,0244	0,034	fail	adequate
Homens	Salário real de admissão (log)	-0,0501***	0,0122	< 0,001	fail	adequate
Homens	Saldo líquido (asinh)	-0,2451	0,3434	0,582	fail	adequate
Mulheres	Admissões (PPML, nível)	-0,0724	0,0464	0,228	fail	adequate
Mulheres	Desligamentos (PPML, nível)	-0,0776*	0,0371	0,095	fail	adequate
Mulheres	Salário real de admissão (log)	-0,0491***	0,0117	< 0,001	fail	adequate
Mulheres	Saldo líquido (asinh)	-1,0188***	0,3015	0,004	fail	adequate

*Notas: cada linha traz o DiD estimado dentro da amostra do próprio grupo, com erro-padrão clusterizado por CBO de quatro dígitos. Família C, de 130 testes; as estrelas são calculadas exclusivamente sobre o p ajustado de Benjamini-Hochberg: | p<0,10; ** p<0,05; *** p<0,01. Estas células não medem heterogeneidade. Como o diferencial nacional de salário real de admissão é de -0,0507 e rejeita a 5%, ele reaparece dentro de praticamente todo grupo: 22 dos 26 grupos da família de 130 testes apresentam queda salarial significativa após o ajuste. O teste de que os grupos diferem entre si é o contraste DDD do Apêndice A, no qual apenas 2 dos 100 contrastes salariais sobrevivem ao mesmo ajuste. As duas leituras são compatíveis: o diferencial é generalizado e a diferença entre grupos não é detectável. O saldo em transformação asinh não deve ser interpretado como percentual. Fonte:*

`results/models/group_did_results.csv`.*


Dentro de cada grupo, o padrão é o mesmo, e é o padrão nacional. As admissões caem cerca de 7,5% entre os homens e 7,0% entre as mulheres; o salário real de admissão cai aproximadamente 4,9% e 4,8%, respectivamente, e rejeita a 5% nos dois casos após o ajuste de multiplicidade. A semelhança entre as duas colunas é, ela própria, o resultado.

O teste de heterogeneidade não encontra assimetria. O DDD de admissões é de **+0,0116**, com p nominal de 0,803 e p ajustado de 0,907: não há diferença detectável entre homens e mulheres na retração das admissões. O mesmo vale para os desligamentos, +0,0332 com BH p = 0,581, e para o salário, +0,0022 com BH p = 0,907. O único contraste de sexo que sobrevive ao ajuste é o saldo líquido, +0,7989 com BH p = 0,0026 — e o saldo é justamente o outcome com o pior diagnóstico de tendências prévias de todo o trabalho, com 21 dos 22 leads individualmente significativos a 5%, de modo que não sustenta leitura causal.

O resultado nulo é informativo e merece ser afirmado como achado, e não como ausência de achado. A Seção 3 mostrou que as mulheres estão desproporcionalmente concentradas nas ocupações mais expostas à IA. Esta subseção mostra que o ajuste do mercado formal após o ChatGPT **não** foi diferencial por sexo. As duas afirmações são compatíveis e, juntas, dizem algo mais preciso do que qualquer uma isolada: a exposição é desigual, o ajuste observado não é, e a desigualdade de exposição ainda não se traduziu em desigualdade de ajuste na porta de entrada.


As Figuras 5.2.1.1 e 5.2.1.2 apresentam os event studies e as trajetórias de admissões e salário de admissão por sexo.

Figura 5.2.1.1: Admissões — event study e trajetórias por sexo



Nota: perfis dinâmicos relativos a novembro de 2022; os diagnósticos nacionais de tendências prévias falham.

Figura 5.2.1.2: Salário real de admissão — event study e trajetórias por sexo



Nota: perfis dinâmicos relativos a novembro de 2022; os diagnósticos nacionais de tendências prévias falham.

Nas admissões, as trajetórias de homens e mulheres em ocupações expostas correm próximas ao longo de todo o período, e a distância entre elas não se destaca nem antes nem depois do evento. Os testes de tendências prévias falham nos dois grupos, de modo que a leitura das figuras é descritiva e serve para mostrar o padrão geral, não para identificar efeito.

No salário, ambos os grupos exibem trajetória posterior abaixo da média do próprio pré-período, com magnitudes muito próximas. É a representação visual do que a tabela mostra: o diferencial salarial existe e não é específico de um sexo.

O resultado converge com [Brynjolfsson, Chandar e Chen \(2025\)](#), que também não encontram efeitos diferenciais por sexo nos Estados Unidos. Permanece válida, e agora isolada, a leitura da Subseção 3.5.1 e de Gmyrek *et al.* (2025) sobre a maior exposição ocupacional das mulheres à IA — que é uma afirmação sobre exposição potencial, e não sobre ajuste realizado. O desenho não observa adoção de IA e não permite afirmar que a exposição potencial esteja se materializando como efeito realizado; o que ele permite afirmar é que, até maio de 2026, ela não se materializou de forma diferencial entre os sexos.

Em resumo, a heterogeneidade por sexo não se confirma. O diferencial pós-ChatGPT nas ocupações expostas é negativo para homens e mulheres, com magnitudes semelhantes nas admissões e praticamente idênticas no salário, e nenhum dos contrastes DDD de admissões, desligamentos ou salário sobrevive ao ajuste de multiplicidade. A afirmação defensável não é, portanto, a de uma retração diferencial das admissões femininas, mas a de que a maior exposição ocupacional das mulheres, documentada na Seção 3, ainda não se manifestou como ajuste diferencial na porta de entrada do emprego formal no período observado. Continua valendo a recomendação de acompanhar a série: ausência de diferença detectável em 42 meses de pós-evento não é o mesmo que ausência de diferença futura.

5.2.2 Efeitos por raça/cor

A Tabela 5.2.2 apresenta os efeitos por raça/cor, comparando trabalhadores brancos e negros, categoria que agrega pretos e pardos. Como na subseção anterior, as células trazem o DiD estimado dentro da amostra de cada grupo; os contrastes DDD, que testam a diferença entre grupos, e a desagregação nas seis categorias do IBGE estão no Apêndice A.

Tabela 5.2.2: Heterogeneidade por raça/cor — Branca e Negra

Grupo	Resultado	DiD no grupo	EP	p BH	Pretrend	Suporte
Branca	Admissões (PPML, nível)	-0,0241	0,0350	0,592	fail	adequate
Branca	Desligamentos (PPML, nível)	-0,0182	0,0250	0,579	fail	adequate
Branca	Salário real de admissão (log)	-0,0544***	0,0114	< 0,001	fail	adequate
Branca	Saldo líquido (asinh)	-0,2246	0,3002	0,569	fail	adequate
Negra (preta e parda)	Admissões (PPML, nível)	-0,0621	0,0446	0,261	fail	adequate
Negra (preta e parda)	Desligamentos (PPML, nível)	-0,0584	0,0396	0,244	fail	adequate
Negra (preta e parda)	Salário real de admissão (log)	-0,0513***	0,0103	< 0,001	fail	adequate
Negra (preta e parda)	Saldo líquido (asinh)	-0,3264	0,2625	0,308	fail	adequate

*Notas: cada linha traz o DiD estimado dentro da amostra do próprio grupo, com erro-padrão clusterizado por CBO de quatro dígitos. Família C, de 130 testes; estrelas calculadas exclusivamente sobre o p ajustado de Benjamini-Hochberg: | p<0,10; ** p<0,05; *** p<0,01. Estas células não medem heterogeneidade; o teste entre grupos é o DDD do Apêndice A. O saldo em transformação asinh não deve ser interpretado como percentual. Fonte:*

`results/models/group_did_results.csv`.*

Dentro de cada grupo, os coeficientes de fluxo são negativos e imprecisos nos dois casos, e o salário cai de forma significativa em ambos — 5,3% entre brancos e 5,0% entre negros. Como na subseção anterior, essa semelhança é o eco do diferencial nacional e não informa sobre heterogeneidade.

O contraste DDD, porém, encontra aqui a heterogeneidade mais robusta de todo o trabalho. A retração dos fluxos nas ocupações expostas é significativamente maior para trabalhadores negros: **-0,1144 nas admissões, -0,0990 nos desligamentos e -0,1068 no fluxo bruto**, os três com p ajustado de 0,015. Em termos aproximados, a queda diferencial é de 10,8% nas admissões e 9,4% nos desligamentos. O salário não acompanha: o DDD é de -0,0121, com p ajustado de 0,399, de modo que o diferencial salarial permanece generalizado e não racialmente diferenciado.

Duas qualificações são obrigatórias na leitura desse resultado. A primeira é que **o efeito está concentrado em pardos**. Na desagregação em seis categorias, o contraste de pardos é de -0,0817 nas admissões, com p ajustado de 0,042, e -0,0886 nos desligamentos, com p ajustado de 0,018, ao passo que o de pretos não é significativo em nenhum


outcome — $-0,0088$ nas admissões, com p ajustado de $0,907$, e $+0,0445$ nos desligamentos, com p ajustado de $0,341$. Agregar as duas categorias produz um resultado forte que descreve mal uma delas.

A segunda é que **o agregado é mais forte que qualquer um de seus componentes**, o que parece contradição e não é. São contrastes diferentes porque os complementos são diferentes: o contraste da categoria *Negra* compara pretos e pardos com brancos, amarelos, indígenas e não identificados; o contraste de *parda*, isoladamente, compara pardos com um complemento que **inclui os pretos**. Como pretos e pardos se movem na mesma direção, separá-los reduz o contraste de cada um. Sem essa frase, um leitor que compare esta tabela com a do Apêndice A conclui que uma das duas está errada.

Cabe registrar ainda um resultado: a categoria **amarela** apresenta os maiores coeficientes de toda a família de contrastes, com $-0,2770$ nas admissões e $-0,2179$ nos desligamentos, ambos com p ajustado abaixo de $0,0001$ e suporte amostral adequado. É um grupo pequeno no mercado formal brasileiro, e o achado deve ser tratado como indicativo, mas omiti-lo seria seletivo.


As Figuras 5.2.2.1 e 5.2.2.2 apresentam os estudos de eventos e as trajetórias normalizadas para admissões e salário real de admissão.

Figura 5.2.2.1 Admissões — event study e trajetórias por raça/cor



Nota: perfis dinâmicos relativos a novembro de 2022; os diagnósticos nacionais de tendências prévias falham.

Figura 5.2.2.2: Salário real de admissão — event study e trajetórias por raça/cor



Nota: perfis dinâmicos relativos a novembro de 2022; os diagnósticos nacionais de tendências prévias falham.

Os pretrends falham nos dois outcomes e nos dois grupos, de modo que as figuras cumprem papel descritivo. Nas admissões, a trajetória dos trabalhadores negros em ocupações expostas se separa da dos brancos ao longo do período posterior, o que é a contrapartida visual do contraste DDD. No salário, as duas trajetórias caem juntas e permanecem próximas, coerentemente com a ausência de heterogeneidade salarial.

Esse resultado qualifica a Subseção 3.5.2. Os trabalhadores brancos estão mais presentes em ocupações altamente expostas, mas o ajuste de fluxo observado após o ChatGPT foi mais intenso entre os negros — isto é, a exposição e o ajuste apontam para lados opostos, e é o ajuste que se materializa na porta de entrada. A comparação internacional permanece limitada, pois os principais estudos empíricos mobilizados nesta dissertação não apresentam estimativas causais desagregadas por raça (Brynjolfsson; Chandar; Chen, 2025; Hosseini Maasoum; Lichtinger, 2025; Klein Teeselink, 2025).

Em resumo, a raça/cor é a dimensão em que a heterogeneidade se sustenta com mais firmeza. A retração dos fluxos nas ocupações expostas foi significativamente maior para trabalhadores negros em admissões, desligamentos e fluxo bruto, com os três contrastes sobrevivendo ao ajuste de multiplicidade. O salário de entrada, por sua vez, cai de modo praticamente idêntico nos dois grupos e não apresenta heterogeneidade racial. Como admissões e desligamentos recuam juntos, o padrão é compatível com menor movimentação dos fluxos entre trabalhadores negros; sem observar o estoque, ele não permite distinguir menor rotatividade de perda líquida de vínculos. E, como o efeito se concentra em pardos, a leitura correta é sobre essa categoria, não sobre a população negra como bloco homogêneo.

5.2.3 Efeitos por faixa etária

A Tabela 5.2.3 apresenta os efeitos por faixa etária, utilizando as faixas da PNAD/IBGE. O Painel A reporta os efeitos DiD dentro de cada grupo. O Painel B, com os contrastes DDD, os diagnósticos de tendências paralelas e as medidas alternativas de saldo, está no apêndice, juntamente com os Painéis A e B da classificação etária adotada por Brynjolfsson, Chandar e Chen (2025).

Tabela 5.2.3: Heterogeneidade por faixa etária — faixas PNAD/IBGE

Faixa etária	Resultado	DiD no grupo	EP	p BH	Pretrend	Suporte
18-24	Admissões (PPML, nível)	-0,0380	0,0360	0,399	fail	adequate
18-24	Desligamentos (PPML, nível)	-0,0170	0,0443	0,753	fail	adequate
18-24	Salário real de admissão (log)	-0,0512***	0,0111	< 0,001	warning	adequate

Faixa etária	Resultado	DiD no grupo	EP	p BH	Pretrend	Suporte
18–24	Saldo líquido (asinh)	–0,0344	0,1930	0,872	fail	adequate
25–34	Admissões (PPML, nível)	–0,0693*	0,0314	0,079	fail	adequate
25–34	Desligamentos (PPML, nível)	–0,0608*	0,0258	0,059	fail	adequate
25–34	Salário real de admissão (log)	–0,0460***	0,0110	< 0,001	fail	adequate
25–34	Saldo líquido (asinh)	–0,5069	0,3529	0,250	fail	adequate
35–44	Admissões (PPML, nível)	–0,0454	0,0343	0,286	fail	adequate
35–44	Desligamentos (PPML, nível)	–0,0398	0,0270	0,244	fail	adequate
35–44	Salário real de admissão (log)	–0,0549***	0,0129	< 0,001	fail	adequate
35–44	Saldo líquido (asinh)	–0,5498	0,3050	0,162	fail	adequate
45–54	Admissões (PPML, nível)	–0,0125	0,0469	0,822	fail	adequate
45–54	Desligamentos (PPML, nível)	–0,0221	0,0325	0,593	fail	adequate
45–54	Salário real de admissão (log)	–0,0417***	0,0114	0,002	warning	adequate
45–54	Saldo líquido (asinh)	–0,2274	0,2270	0,425	fail	adequate
55–65	Admissões (PPML, nível)	–0,0399	0,0678	0,646	fail	adequate
55–65	Desligamentos (PPML, nível)	–0,0860*	0,0394	0,082	fail	adequate
55–65	Salário real de admissão (log)	–0,0448***	0,0129	0,003	fail	adequate
55–65	Saldo líquido (asinh)	0,3794**	0,1345	0,020	fail	adequate

*Notas: cada linha traz o DiD estimado dentro da amostra da própria faixa, com erro-padrão clusterizado por CBO de quatro dígitos. Família C, de 130 testes; estrelas calculadas exclusivamente sobre o p ajustado de Benjamini-Hochberg: | p<0,10; ** p<0,05; *** p<0,01. Estas células não medem heterogeneidade; o teste entre faixas é o DDD do Apêndice A. A amostra é restrita a trabalhadores de 18 a 65 anos. Fonte: [results/models/group_did_results.csv](#).**

Dentro de cada faixa, os coeficientes de admissão são negativos e majoritariamente imprecisos, e o salário de entrada cai de forma significativa em **todas** as cinco faixas, entre 4,2% e 5,5%. A queda salarial, portanto, não é um fenômeno de jovens: ela atravessa a distribuição etária inteira.


O contraste DDD **inverte a leitura da versão anterior deste trabalho**. Nas coortes do artigo de referência, o contraste da faixa de 22 a 25 anos nas admissões é de apenas –0,0189, com p ajustado de 0,652: não há retração diferencial dos mais jovens. O contraste que sobrevive ao ajuste é o da faixa de **41 a 49 anos**, e ele é **positivo**: +0,0841 nas admissões, com p ajustado de 0,0043, +0,0699 nos desligamentos, com p ajustado de 0,027, e +0,0776 no fluxo bruto, com p ajustado de 0,0089.

A formulação correta, portanto, não é a de que os jovens foram atingidos, e sim a de que **os trabalhadores de 41 a 49 anos foram poupados**. É a mesma configuração de dados vista de outro ângulo, mas a diferença não é retórica: ela muda o mecanismo que se pode invocar e muda a comparação com a literatura. As faixas intermediárias acompanham o padrão de forma graduada — 26 a 30 anos com –0,0105, 31 a 34 com +0,0253 e 35 a 40 com +0,0353 —, nenhuma delas sobrevivendo ao ajuste, o que é coerente com um gradiente cuja única extremidade detectável é a superior.

No salário, nenhum contraste etário sobrevive ao ajuste: o DDD da faixa de 22 a 25 anos é de –0,0004, com p ajustado de 0,974. O diferencial salarial é generalizado e não etário.


As Figuras 5.2.3.1 e 5.2.3.2 apresentam os event studies e as trajetórias de admissões e salário real de admissão para todas as faixas da PNAD/IBGE. Os painéis superiores mostram os coeficientes mensais do DDD e os respectivos intervalos de confiança, enquanto os painéis inferiores apresentam as trajetórias descritivas das ocupações expostas e não expostas dentro de cada faixa.

Figura 5.2.3.1: Heterogeneidade por idade — Admissões



Nota: perfis dinâmicos relativos a novembro de 2022; os diagnósticos nacionais de tendências prévias falham.

Figura 5.2.3.2: Heterogeneidade por idade — Salário real de admissão




Nota: perfis dinâmicos relativos a novembro de 2022; os diagnósticos nacionais de tendências prévias falham.

Os diagnósticos de tendências prévias falham em quase todas as células, com exceção de dois alertas no salário, nas faixas de 18 a 24 e de 45 a 54 anos. As figuras, portanto, evidenciam comportamentos distintos entre as faixas, mas não estabelecem hierarquia etária causal.

Há, contudo, uma exceção que merece parágrafo próprio, porque é o único contraste desta dissertação cuja identificação sobrevive ao diagnóstico. No DiD estimado **dentro** da coorte de 22 a 25 anos, o salário real de admissão cai $-0,0517$, com p nominal de 1×10^{-6} e p ajustado de 4×10^{-5} , **e o teste conjunto de tendências paralelas passa**, com $p = 0,585$. Em todo o restante do trabalho — 51 células de diagnóstico nacional e praticamente todas as células de grupo — esse teste é rejeitado. Aqui ele não é.

A ressalva é obrigatória e deve acompanhar a afirmação: trata-se de 1 entre 100 contrastes de diagnóstico, sem ajuste de multiplicidade sobre a família de pretrends, de modo que a sobrevivência de um teste entre muitos é esperada por acaso. O achado não prova a exceção; ele a exhibe. Ainda assim, merece destaque por duas razões: alinha-se ao enquadramento de porta de entrada que organiza esta dissertação e recai justamente sobre a coorte que o artigo de referência identifica como a mais afetada. A Figura 5.2.3.3 mostra esse contraste isoladamente: os coeficientes pré-tratamento oscilam em torno de $+0,0064$, sem tendência e sem nenhum lead individualmente significativo a 5%, e a trajetória posterior se estabelece de forma persistente abaixo dessa média. A distância entre a linha tracejada e o pós-evento é de $-0,0507$, praticamente idêntica ao DiD de $-0,0517$ estimado dentro do grupo.

Figura 5.2.3.3: Coorte de 22 a 25 anos — salário real de admissão



Os resultados brasileiros não reproduzem, nas admissões, a concentração do efeito entre 22 e 25 anos encontrada por [Brynjolfsson, Chandar e Chen \(2025\)](#), que reportam queda de cerca de 12 pontos log para essa coorte. A comparação precisa ser feita com cuidado, porque os dois trabalhos localizam o contraste em pontos diferentes da distribuição etária: lá, o efeito está nos jovens; aqui, o que gera o contraste é a ausência de efeito entre os de 41 a 49 anos. A diferença pode decorrer dos desenhos: os autores analisam o estoque de emprego e comparam quintis de exposição, com efeitos concentrados nos níveis mais elevados, enquanto esta dissertação examina fluxos de admissões e desligamentos e utiliza uma classificação binária mais ampla de ocupações expostas. Vale notar, porém, que na margem salarial a coorte de 22 a 25 anos é justamente aquela em que o resultado brasileiro é mais bem identificado.

Além disso, enquanto Hosseini Maasoum e Lichtinger encontram redução do emprego júnior principalmente pela desaceleração das contratações, o resultado mais preciso desta análise está na queda dos desligamentos.

Em resumo, a maior exposição dos jovens documentada na Seção 3.5.3 não se converte em retração diferencial das admissões entre os mais jovens. O único contraste etário que sobrevive ao ajuste de multiplicidade é positivo e está na faixa de 41 a 49 anos, o que se lê como proteção relativa dos trabalhadores de meia-idade, e não como punição dos jovens.

Na margem salarial, a queda é generalizada e atinge todas as faixas com magnitude semelhante, sem heterogeneidade etária detectável. O resultado mais bem identificado do trabalho, entretanto, está nessa margem e nessa coorte: dentro do grupo de 22 a 25 anos, a queda do salário de entrada é precisa e é o único contraste cujo diagnóstico de tendências paralelas não é rejeitado — com a ressalva, já declarada, de que se trata de um teste entre cem.

5.2.4 Efeitos por nível de escolaridade

A Tabela 5.2.4 apresenta os efeitos por nível de escolaridade. O Painel A reporta os efeitos DiD dentro de cada grupo. Os contrastes DDD, os diagnósticos de tendências paralelas e as medidas alternativas de saldo estão no Painel B, no apêndice.

Tabela 5.2.4: Heterogeneidade por nível de escolaridade

Grupo	Resultado	DiD no grupo	EP	p BH	Pretrend	Suporte
Fundamental ou menos	Admissões (PPML, nível)	0,0018	0,0531	0,974	fail	adequate
Fundamental ou menos	Desligamentos (PPML, nível)	0,0141	0,0469	0,800	fail	adequate
Fundamental ou menos	Salário real de admissão (log)	-0,0080	0,0144	0,661	fail	adequate
Fundamental ou menos	Saldo líquido (asinh)	0,3330	0,1668	0,112	fail	adequate
Médio	Admissões (PPML, nível)	-0,0438	0,0314	0,261	fail	adequate
Médio	Desligamentos (PPML, nível)	-0,0455	0,0307	0,244	fail	adequate
Médio	Salário real de admissão (log)	-0,0427***	0,0122	0,003	fail	adequate
Médio	Saldo líquido (asinh)	-0,2973	0,3251	0,470	fail	adequate
Superior	Admissões (PPML, nível)	-0,1075**	0,0371	0,017	fail	adequate
Superior	Desligamentos (PPML, nível)	-0,0939**	0,0363	0,035	fail	adequate
Superior	Salário real de admissão (log)	-0,0352***	0,0093	0,001	fail	adequate
Superior	Saldo líquido (asinh)	-1,1562***	0,3173	0,002	fail	adequate

*Notas: cada linha traz o DiD estimado dentro da amostra do próprio grupo, com erro-padrão clusterizado por CBO de quatro dígitos. Família C, de 130 testes; estrelas calculadas exclusivamente sobre o p ajustado de Benjamini-Hochberg: † p<0,10; ** p<0,05; *** p<0,01. Estas células não medem heterogeneidade; o teste entre grupos é o DDD do Apêndice A. Fonte: [results/models/group_did_results.csv](#).**

Os efeitos negativos de fluxo concentram-se nos trabalhadores com ensino superior. Dentro desse grupo, as admissões recuam -0,1075, com p ajustado de 0,017, e os desligamentos -0,0939, com p ajustado de 0,035, ao passo que os níveis médio e fundamental não apresentam movimento significativo nos fluxos. O salário, como em toda parte, cai nos três níveis com exceção do fundamental.


No contraste DDD, a direção se mantém e a magnitude é grande, **mas a significância fica no limite depois do ajuste de multiplicidade**, e isso precisa ser dito com precisão. O contraste do ensino superior nas admissões é de -0,1108, com p nominal de 0,0145 e **p ajustado de 0,055** — fora do limiar de 5%, portanto, ainda que por pouco. Nos desligamentos ocorre o mesmo, com -0,1064 e p ajustado de 0,055. Dois contrastes do grupo sobrevivem ao ajuste: o fluxo bruto, com -0,1083 e p ajustado de 0,048, e o saldo líquido, com -0,8421 e p ajustado de 0,015. O sentido oposto também aparece: o contraste do ensino fundamental é positivo, com +0,1231 nas admissões, também no limite, e saldo de +0,9560 com p ajustado de 0,043.

A afirmação defensável é, portanto, que a retração dos fluxos foi mais forte entre trabalhadores com ensino superior, com a qualificação de que, nas duas margens mais diretas — admissões e desligamentos —, o contraste não ultrapassa o limiar ajustado, e o que o ultrapassa são as medidas agregadas de fluxo bruto e saldo. Não há heterogeneidade salarial: o DDD do ensino superior no salário é de +0,0076, com p ajustado de 0,707.

As Figuras 5.2.4.1 e 5.2.4.2 apresentam os event studies e as trajetórias de admissões e salário real de admissão por escolaridade.

Figura 5.2.4.1: Admissões — event study e trajetórias por escolaridade


Figura 5.2.4.1 — Escolaridade — Admissões



Nota: perfis dinâmicos relativos a novembro de 2022; os diagnósticos nacionais de tendências prévias falham.

Figura 5.2.4.2: Salário real de admissão — event study e trajetórias por escolaridade

Figura 5.2.4.2 — Escolaridade — Salário real de admissão



Nota: perfis dinâmicos relativos a novembro de 2022; os diagnósticos nacionais de tendências prévias falham.

Nas admissões, as trajetórias do ensino superior mantêm as ocupações expostas abaixo das não expostas ao longo do pós-evento, e a separação entre os níveis educacionais é visível. O pretrend, porém, falha em todas as células, o que limita a leitura ao plano descritivo. Nos salários, as trajetórias dos três níveis caem de forma paralela, reforçando visualmente a ausência de heterogeneidade salarial.

O resultado converge com a Subseção 3.5.4, que mostrou aumento expressivo da exposição à IA com a escolaridade. Também é compatível com [Klein Teeselink \(2025\)](#), que encontra efeitos concentrados em firmas e ocupações de alta remuneração no Reino Unido. A comparação não é direta, pois remuneração não equivale a escolaridade. [Brynjolfsson,](#)

Chandar e Chen (2025), mostram ainda que ocupações com menor proporção de graduados também podem ser afetadas, enquanto Hosseini Maasoum e Lichtinger (2025) identificam diferenças importantes dentro do próprio ensino superior.

Em resumo, a heterogeneidade educacional é a mais próxima do limiar sem cruzá-lo nas margens principais: a direção e a magnitude do efeito nos trabalhadores com ensino superior são claras, mas o p ajustado de admissões e desligamentos fica em 0,055, e apenas o fluxo bruto e o saldo sobrevivem ao ajuste. Não há diferença salarial por escolaridade nem evidência segura de contração líquida do emprego.

5.2.5 Efeitos por faixa salarial ocupacional

Tabela 5.2.5: Efeitos dentro dos grupos por faixa salarial ocupacional

Faixa de renda	Resultado	DiD no grupo	EP	p BH	Pretrend	Suporte
Até 2 SM	Admissões (PPML, nível)	-0,0304	0,0321	0,453	fail	adequate
Até 2 SM	Desligamentos (PPML, nível)	-0,0409	0,0299	0,271	fail	adequate
Até 2 SM	Salário real de admissão (log)	-0,0493***	0,0140	0,003	fail	adequate
Até 2 SM	Saldo líquido (asinh)	0,2144	0,3569	0,642	fail	adequate
Mais de 2 a 5 SM	Admissões (PPML, nível)	-0,1914**	0,0664	0,021	fail	limited
Mais de 2 a 5 SM	Desligamentos (PPML, nível)	-0,1028	0,0800	0,298	fail	limited
Mais de 2 a 5 SM	Salário real de admissão (log)	-0,0434	0,0258	0,198	fail	limited
Mais de 2 a 5 SM	Saldo líquido (asinh)	-1,2484	0,8350	0,244	warning	limited
Mais de 5 SM	Admissões (PPML, nível)	-0,0068	0,0954	0,952	fail	thin
Mais de 5 SM	Desligamentos (PPML, nível)	0,1564	0,1053	0,272	not_estimated	thin
Mais de 5 SM	Salário real de admissão (log)	0,0117	0,0345	0,785	fail	thin
Mais de 5 SM	Saldo líquido (asinh)	-3,4227	2,1171	0,244	fail	thin

*Notas: cada linha traz o DiD estimado dentro da amostra da própria faixa, com erro-padrão clusterizado por CBO de quatro dígitos. Família C, de 130 testes; estrelas calculadas exclusivamente sobre o p ajustado de Benjamini-Hochberg: | p<0,10; ** p<0,05; *** p<0,01. As faixas utilizam a mediana salarial pré-tratamento da CBO, expressa em salários mínimos, e não a renda individual corrente. A coluna de suporte é parte do resultado: **limited** indica 26 CBOs tratadas e 32 de controle; **thin** indica 3 tratadas e 6 de controle, base insuficiente para inferência substantiva. **not_estimated** no pretrend registra que a inclinação GLS não é identificada naquela célula. Fonte: `results/models/group_did_results.csv`.**

O único movimento nominavelmente forte está nas admissões da faixa de 2 a 5 salários mínimos, com -0,1914 e p ajustado de 0,021 no DiD dentro do grupo. Ele deve ser lido com a coluna de suporte ao lado: a faixa reúne 26 CBOs tratadas e 32 de controle, o que a classifica como suporte **limited**.

O contraste DDD, porém, **não sustenta** de que a redução dos desligamentos se concentraria na renda intermediária. O DDD de desligamentos dessa faixa é de -0,0543, com p ajustado de 0,707, e o de admissões é de -0,1474, com p ajustado de 0,164. Nenhum dos quinze contrastes de renda sobrevive ao ajuste de multiplicidade com suporte adequado.


Na faixa de até 2 salários mínimos, nem os efeitos dentro do grupo nem os contrastes DDD são significativos depois do ajuste: as admissões dão +0,1183 com p ajustado de 0,325. Os sinais positivos que a versão anterior reportava nessa faixa não sobrevivem à safra reconstruída nem à correção de multiplicidade.

Acima de 5 salários mínimos, a limitação é severa: a comparação depende de 3 CBOs tratadas e 6 de controle. Existe nessa faixa um contraste DDD de salário positivo que sobrevive nominalmente ao ajuste, mas ele repousa sobre três

ocupações tratadas e, por isso, **fica registrado na tabela com o rótulo de suporte *thin* e não é usado como base de afirmação**. Três ocupações não sustentam uma conclusão sobre o topo da distribuição de renda, e reportar o p-valor sem reportar o suporte seria enganoso.

A Figura 5.2.5.1 apresenta os event studies e as trajetórias das admissões por renda pré-tratamento.

Figura 5.2.5.1: Admissões — event studies e trajetórias por renda pré-tratamento




Nota: perfis dinâmicos relativos a novembro de 2022; os diagnósticos nacionais de tendências prévias falham.

A maior volatilidade da faixa superior decorre do pequeno número de ocupações: os coeficientes dependem de apenas 3 CBOs expostas e 7 não expostas, o que amplia a incerteza das estimativas.

A Figura 5.2.5.2 apresenta os resultados para o salário real de admissão.

Figura 5.2.5.2: Salário real de admissão — event studies e trajetórias por renda pré-tratamento



Nota: perfis dinâmicos relativos a novembro de 2022; os diagnósticos nacionais de tendências prévias falham.

Os coeficientes salariais oscilam em torno de zero e seus intervalos de confiança são amplos. Os testes conjuntos não rejeitam os pretrends nas duas primeiras faixas ($p=0,417$ e $p=0,277$), mas ambas são classificadas como falha porque apresentam três coeficientes pré-tratamento individualmente significativos. No topo, o teste conjunto é limitrofe ($p=0,057$) e gera alerta. Não há, portanto, evidência de heterogeneidade salarial robusta.

O resultado dialoga com a Subseção 3.5.5, que mostrou que a alta exposição cresce até as faixas intermediárias e depois se estabiliza. A comparação é apenas indicativa, pois aquela análise classifica trabalhadores por renda, enquanto esta utiliza a mediana salarial da CBO. O padrão também converge parcialmente com [Klein Teeselink \(2025\)](#), que encontra maior ajuste nos segmentos de alta remuneração do Reino Unido e pouca alteração nos de baixa remuneração. A correspondência não é exata: nesta dissertação, o sinal concentra-se na faixa intermediária e o topo possui suporte insuficiente. Já a ausência de efeitos salariais é compatível com [Brynjolfsson, Chandar e Chen \(2025\)](#), que encontram ajustes mais visíveis no emprego do que na remuneração.

Em resumo, a renda ocupacional é a dimensão em que **nada se sustenta**. Nenhum contraste DDD de renda sobrevive ao ajuste de multiplicidade com suporte adequado, e o único que sobrevive tem suporte **thin**. A afirmação da versão anterior sobre concentração do efeito na faixa intermediária não se sustenta. Não há base para concluir que a IA protege o topo, produz compressão salarial ou reduz o emprego líquido em qualquer faixa de renda. O que resta é o diferencial salarial nacional, que reaparece na faixa de até 2 salários mínimos por ser ela a que concentra a maior parte da amostra.

5.2.6 Síntese das heterogeneidades demográficas

A análise por grupos demográficos parte de uma base comum aos cinco recortes: o diferencial salarial nacional, de $-0,0507$, reaparece dentro de praticamente todo grupo — 22 dos 26 grupos da família de 130 testes exibem queda salarial significativa depois do ajuste. Esse eco não é heterogeneidade; é o efeito médio visto de perto. A pergunta de heterogeneidade é outra, e responde-se pelo contraste de diferença tripla.

Dos **100 contrastes de diferença tripla**, **34 são nominalmente significativos a 5%** e **21 sobrevivem ao ajuste de Benjamini-Hochberg**. A heterogeneidade detectável concentra-se em **raça/cor** e em **faixa etária**; sexo e renda não apresentam diferencial robusto, e escolaridade fica no limite da significância ajustada.


Os cinco eixos resumidos. **Sexo**: nenhum contraste de fluxo ou salário sobrevive; a maior exposição ocupacional das mulheres não se converteu em ajuste diferencial. **Raça/cor**: é o eixo mais firme, com retração de fluxos significativamente maior entre trabalhadores negros em admissões, desligamentos e fluxo bruto, efeito concentrado em pardos. **Idade**: o único contraste que sobrevive é positivo e está entre 41 e 49 anos, o que se lê como proteção dos trabalhadores de meia-idade e não como punição dos jovens. **Escolaridade**: direção e magnitude claras no ensino

superior, mas p ajustado de 0,055 nas admissões e nos desligamentos, com apenas fluxo bruto e saldo cruzando o limiar. **Renda:** nada se sustenta com suporte adequado.

O salário de admissão merece registro à parte por razão oposta: ele é o resultado mais forte do trabalho no nível nacional e o mais uniforme entre grupos. Apenas 2 dos 100 contrastes salariais de diferença tripla sobrevivem ao ajuste. As duas leituras são compatíveis e devem ser apresentadas juntas: o diferencial salarial é generalizado, e a diferença entre grupos não é detectável.

A **Figura 5.2.6** reúne os 130 contrastes de DiD dentro do grupo em um único gráfico, facetado por outcome, com os intervalos ajustados por Benjamini-Hochberg e marcação das células de suporte `limited` e `thin`. Ela torna visível de uma só vez o que as cinco subseções dizem em partes: a multiplicidade dos testes, o domínio do salário sobre os demais outcomes e a raridade dos contrastes que sobrevivem.

Figura 5.2.6 — DiD dentro dos grupos por outcome



DiD dentro do grupo não mede heterogeneidade: 22/26 quedas salariais sobrevivem ao BH na Família C, enquanto 2/100 DDD salariais sobrevivem na Família A.

Em conjunto, esses resultados qualificam o quadro da Seção 5.1 em duas direções opostas. De um lado, o diferencial salarial é mais sólido do que a média nacional sugeria isoladamente, porque reaparece em praticamente todo grupo.

A relação com o retrato descritivo da Seção 3 também muda, e para melhor. Não é verdade que os perfis mais expostos sejam os que concentram os sinais de ajuste: as mulheres e os trabalhadores de maior escolaridade estão entre os mais expostos, e o ajuste diferencial não aparece com robustez em nenhum dos dois; a retração de fluxo mais

filme recai sobre trabalhadores negros, que **não** estão entre os mais expostos. Exposição potencial e ajuste realizado, portanto, não coincidem — e essa não coincidência é um resultado, não uma falha do desenho.

A leitura deve permanecer cautelosa pelas razões já declaradas: a exposição não mede adoção, o estoque não é observado, e os testes de tendências paralelas são rejeitados em praticamente todas as células. Nesse quadro, a expressão **acomodação silenciosa** deve ser apresentada apenas como hipótese de discussão, e com uma ressalva adicional: a decomposição dos desligamentos por motivo, examinada na seção de robustez, não a corrobora. O padrão de queda simultânea de entradas e saídas nas ocupações expostas é real e merece acompanhamento; o mecanismo que o produz permanece não identificado por este desenho.

5.3 Casos ocupacionais e trajetórias por idade

Para aproximar a discussão brasileira dos seis exemplos de *Canaries in the Coal Mine*, esta subseção acompanha as trajetórias de seis casos ocupacionais definidos semanticamente a partir das descrições oficiais da CBO de seis dígitos. A seleção foi congelada antes da inspeção dos resultados e reúne 76 códigos sem sobreposição. Para cada caso, calculo mensalmente as admissões e o salário real médio dos admitidos nas faixas de 22–25, 26–30, 31–34, 35–40, 41–49 e 50 anos ou mais, normalizando **novembro de 2022** em 1, a mesma referência usada nos estudos de eventos das subseções anteriores. A medida resumida no texto é a média dos **doze meses terminais**, de junho de 2025 a maio de 2026, em relação a essa base; um recorte de doze meses neutraliza a sazonalidade, que um recorte semestral não neutraliza. Como não há um grupo de controle próprio para cada caso, as figuras são descritivas: seus diagnósticos anteriores ao choque medem cobertura, inclinação e volatilidade, mas não constituem testes causais de tendências paralelas. Nos salários, valores positivos foram winsorizados nos percentis 1 e 99 dentro de cada CBO de seis dígitos e ano, pois os registros brutos continham valores manifestamente implausíveis; as médias sem esse ajuste ficam disponíveis no pacote de replicação.

A Tabela 5.3.1 mostra que a correspondência semântica não produz uma ordenação brasileira idêntica à do artigo. Desenvolvedores concentram 64,6% das admissões prévias no Gradiente 3 e 29,9% no Gradiente 2 da OIT, enquanto atendimento está integralmente no Gradiente 3 e marketing e vendas, no Gradiente 2. Em contraste, supervisores de produção são majoritariamente não expostos (58,3%) ou não possuem escore (36,2%); estoquistas e repositores estão integralmente em exposição mínima; e auxiliares de saúde e cuidado combinam ocupações não expostas (62,4%) e minimamente expostas (37,6%). Essa composição é usada para interpretar os casos depois de selecionados, não para criar novos rótulos de exposição; em particular, ausência de escore não significa exposição zero.

Tabela 5.3.1: Seleção e composição da exposição dos casos ocupacionais

Caso ocupacional	CBOs (n)	Confiança semântica	Referência em <i>Canaries</i>	Composição OIT no Brasil	Admissões pré-tratamento
Desenvolvedores de software	7	Alta	Alta exposição	G3 64,6%; G2 29,9%; sem escore 5,5%	293.893
Atendimento ao cliente	2	Alta	Alta exposição	G3 100,0%	160.341
Gerentes de marketing e vendas	2	Alta	Quartil 4	G2 100,0%	68.132
Supervisores de produção	53	Moderada	Quartil 3	não exposto 58,3%; exposição mínima 5,5%; sem escore 36,2%	62.953
Estoquistas e repositores	5	Alta	Quartil 2	exposição mínima 100,0%	1.593.069
Auxiliares de saúde e cuidado	7	Moderada	Quartil 1	não exposto 62,4%; exposição mínima 37,6%	147.801

*Nota: a composição da OIT é ponderada pelas admissões entre janeiro de 2021 e outubro de 2022. A seleção dos casos usa títulos e tarefas oficiais da CBO de seis dígitos e é independente dessa classificação. A composição do dicionário precisa ser declarada, porque ela não é equilibrada: dos 76 códigos principais, 53 pertencem a um único caso, o de supervisores de produção, e dos 80 mapeamentos registrados 60 têm confiança **medium**, não **high**. A cobertura de escore da OIT também varia entre os casos, de 63,8% em supervisores a 100% em quatro deles. Por isso o caso de supervisores é o menos homogêneo do conjunto e o que menos suporta leitura substantiva.*

Dicionário congelado com SHA-256 [b8d0310606c37ed3...](#); fonte: [results/tables/table_5_3_1_occupation_cases.md](#).

Figura 5.3.1: Trajetórias mensais de admissões por caso ocupacional e idade

Séries descritivas normalizadas em novembro de 2022. Não há grupo de comparação específico por caso; não são exibidos intervalos de confiança.

medium

Figura 5.3.2: Trajetórias mensais do salário real de admissão por caso ocupacional e idade

Figura 5.3.2 — Salário real de admissão por caso e idade



O salário real de admissão acrescenta uma margem distinta, porém menos uniforme e sem a inclinação etária nítida das admissões. **Atendimento ao cliente** é positivo nas seis idades, de +7,8% a +12,8%, e **estoquistas** também, de +5,7% a +7,5%. **Auxiliares de saúde e cuidado** é o único caso com quedas expressivas, de -11,3% a -25,1% acima dos 26 anos; a forte volatilidade prévia e a combinação de ocupações clínicas e de cuidado exigem cautela adicional. **Marketing e vendas**, que a versão anterior descrevia como predominantemente negativo, apresenta agora variações positivas em cinco das seis faixas, chegando a +16,6% acima de 50 anos. **Software** fica próximo de zero em quatro faixas, com -6,9% entre 22 e 25 anos e -5,4% acima de 50, e **supervisores** oscilam entre 0,1% e 9,0%. A magnitude dessas oscilações é pequena diante da variação mensal das próprias séries, de modo que a leitura substantiva se restringe aos dois casos com sinal uniforme nas seis idades — atendimento e estoquistas — e ao de auxiliares de saúde.

O recorte etário, portanto, reforça uma assimetria na porta de entrada, mas de forma mais estreita do que a versão anterior deste trabalho afirmava. **A contratação mais fraca entre jovens aparece em um caso, não em dois:** atendimento ao cliente. Software, que era o outro, ficou estável nas faixas jovens. O que se generaliza é a inclinação etária — em todos os seis casos as faixas mais velhas crescem mais que as jovens —, e essa inclinação é compatível

tanto com uma reconfiguração das oportunidades de entrada quanto com o envelhecimento da população ocupada e com mudanças de composição que este exercício não isola.

Cabe registrar uma limitação de dado que fecha uma porta analítica. O campo `tipomovimentacao` do CAGED, que distingue as modalidades de entrada e de saída, é preenchido como “tipo ignorado” em **93,2% das admissões** e em apenas 0,08% dos desligamentos. Isso valida a decomposição dos desligamentos por motivo, usada na seção de robustez, e **inviabiliza** qualquer decomposição simétrica da porta de entrada por tipo de admissão — primeiro emprego contra reemprego, por exemplo —, que seria o exercício natural para separar entrada de recolocação. A limitação é da base, não do desenho.

Em conjunto, os casos brasileiros dialogam com [Brynjolfsson, Chandar e Chen \(2025\)](#), ao localizar o ajuste mais visível nas contratações de trabalhadores mais jovens em ocupações ligadas a software e atendimento. A comparação, entretanto, não é equivalente: o artigo acompanha estoque de emprego em firmas, enquanto o CAGED registra fluxo de admissões formais, e a classificação de exposição da OIT também difere dos quintis utilizados pelos autores. Assim, esta subseção não altera a conclusão causal das Seções 5.1 e 5.2. Seu papel é mostrar que a média nacional encobre trajetórias ocupacionais e etárias bastante distintas, compatíveis com uma reconfiguração seletiva das oportunidades de entrada, mas também com sazonalidade, composição ocupacional e outros choques não isolados por este exercício.

Apêndice A: Contrastes DDD e diagnósticos das heterogeneidades

Este apêndice reúne os contrastes entre cada grupo e seu complemento, estimados por diferenças em diferenças triplas (DDD), além dos diagnósticos de tendências prévias, suporte amostral e tamanho das amostras. Os diagnósticos de pretrend das heterogeneidades testam uma tendência linear no período anterior ao tratamento e, portanto, não correspondem ao teste conjunto do estudo de eventos nacional. Os p-valores são convencionais e não recebem correção por testes múltiplos. As análises devem ser consideradas exploratórias, sobretudo quando o pretrend falha ou o suporte é classificado como insuficiente.

A.1 Diagnósticos do modelo nacional

Tabela A.1: Diagnósticos dos resultados médios nacionais

Painel B.1: Estimativas DiD e diagnósticos dos outcomes principais

Resultado	DiD nacional	p DiD	Pretrend	p pretrend	N	CBOs
Admissões (PPML, nível)	-0,0538 (0,0386)	0,164	fail	p<0,001	22.049	341
Desligamentos (PPML, nível)	-0,0420 (0,0347)	0,227	fail	p<0,001	22.049	341
Fluxo bruto (PPML, nível)	-0,0481 (0,0353)	0,174	fail	p<0,001	22.049	341
Salário real de admissão (log)	-0,0507*** (0,0103)	p<0,001	fail	p=1,6e-04	22.012	341
Saldo líquido (asinh)	-0,5513 (0,3783)	0,146	fail	p<0,001	22.049	341

Painel B.2: Proxy cumulativo de fluxo líquido

Resultado	DiD nacional	p DiD	Pretrend	N	CBOs
Proxy cumulativo de fluxo líquido	1,4292 (1,3093)	0,276	not_available	22.100	340

Notas: as células do Painel B.1 apresentam o coeficiente e, entre parênteses, o erro-padrão clusterizado por CBO de quatro dígitos, com inferência baseada na distribuição t com G-1 graus de liberdade. * p<0,10; ** p<0,05; *** p<0,01. Admissões, desligamentos e fluxo bruto são estimados por PPML, e o coeficiente é semi-elasticidade da média condicional em nível, não log-log. O tratamento compara CBOs expostas nos gradientes da OIT a CBOs `Not Exposed`; `Minimal Exposure` não integra o controle principal. **Os cinco pretrends falham**, incluindo o do salário real de admissão, cujo teste conjunto tem p=1,6e-04 e 11 dos 22 leads individualmente significativos — na versão anterior esta célula reportava `pass (p=0,932)`, o que a safra reconstruída não sustenta. O pretrend é o teste conjunto dos coeficientes mensais anteriores ao tratamento, estimado sobre o modelo exato do event study. `asinh(saldo)` aceita valores negativos e zero e não deve ser interpretado como percentual. O Painel B.2 substitui as duas construções alternativas do saldo por um índice cumulativo de fluxo líquido, normalizado pelo fluxo bruto pré-tratamento; **ele não observa o estoque de emprego** e não deve ser lido como tal. Uma CBO é excluída do proxy por ter fluxo bruto pré-tratamento igual a zero. Os

p-valores desta tabela são convencionais e não recebem correção por testes múltiplos, que se aplica às famílias de heterogeneidade do Apêndice A. N denota observações CBO-mês, não trabalhadores. Esta é a única tabela do trabalho que mantém um Painel B.2.

A.2 Sexo

Tabela A.2: Contrastes DDD por sexo

Contrastes DDD · **Família A**, de 100 testes

Grupo	Resultado	DDD (EP)	p nominal	p BH	Pretrend grupo	Pretrend DDD	MDE 80%
Homens	Admissões (PPML, nível)	0,0116 (0,0466)	0,803	0,907	fail	fail	0,0765
Homens	Desligamentos (PPML, nível)	0,0332 (0,0390)	0,395	0,581	fail	fail	0,0685
Homens	Fluxo bruto (PPML, nível)	0,0216 (0,0420)	0,607	0,742	fail	fail	0,0655
Homens	Salário real de admissão (log)	0,0022 (0,0100)	0,824	0,907	fail	fail	0,0342
Homens	Saldo líquido (asinh)	0,7989 (0,2145)	< 0,001	0,003	fail	fail	0,9649
Mulheres	Admissões (PPML, nível)	-0,0116 (0,0466)	0,803	0,907	fail	fail	0,1302
Mulheres	Desligamentos (PPML, nível)	-0,0332 (0,0390)	0,395	0,581	fail	fail	0,1043
Mulheres	Fluxo bruto (PPML, nível)	-0,0216 (0,0420)	0,607	0,742	fail	fail	0,1142
Mulheres	Salário real de admissão (log)	-0,0022 (0,0100)	0,824	0,907	fail	fail	0,0329
Mulheres	Saldo líquido (asinh)	-0,7989 (0,2145)	< 0,001	0,003	fail	fail	0,8472

Notas: as células trazem o coeficiente DDD e, entre parênteses, o erro-padrão clusterizado por CBO de quatro dígitos. O DDD é a interação $pós \times exposta \times grupo$ e testa se o efeito do grupo difere do de seu complemento — é este, e não o DiD dentro do grupo da Seção 5.2, o teste de heterogeneidade. Família A, de 100 testes, com ajuste de Benjamini-Hochberg; o p nominal e o p ajustado aparecem lado a lado justamente para que a diferença entre os dois fique visível. Os diagnósticos de pretrend das heterogeneidades testam uma tendência linear no pré-período e não são o teste conjunto do event study nacional; os dez contrastes desta tabela têm pretrend **fail**. MDE 80% é o efeito mínimo detectável a 80% de poder, útil para separar ausência de efeito de ausência de precisão. N denota observações CBO-mês, não trabalhadores; o suporte classifica-se como **adequate** a partir de 20 CBOs tratadas e 50 de controle, **limited** a partir de 10/25 e **thin** abaixo disso. **asinh(saldo)** aceita valores negativos e zero e não deve ser interpretado como percentual. Em dimensões binárias, os DDDs dos dois grupos são espelhados por construção e não constituem testes independentes. Fonte: [results/diagnostics/ddd_multiplicity_results.csv](#).]

A.3 Raça/cor

Tabela A.3: Contrastes DDD por raça/cor — seis categorias

Contrastes DDD · **Família A**, de 100 testes

Grupo	Resultado	DDD (EP)	p nominal	p BH	Pretrend grupo	Pretrend DDD	MDE 80%
Branca	Admissões (PPML, nível)	0,0827 (0,0188)	< 0,001	< 0,001	fail	fail	0,0982
Branca	Desligamentos (PPML, nível)	0,0651 (0,0136)	< 0,001	< 0,001	fail	fail	0,0703
Branca	Fluxo bruto (PPML, nível)	0,0743 (0,0144)	< 0,001	< 0,001	fail	fail	0,0794

Grupo	Resultado	DDD (EP)	p nominal	p BH	Pretrend grupo	Pretrend DDD	MDE 80%
Branca	Salário real de admissão (log)	-0,0080 (0,0088)	0,361	0,556	fail	fail	0,0320
Branca	Saldo líquido (asinh)	0,7390 (0,2544)	0,004	0,026	fail	fail	0,8436
Preta	Admissões (PPML, nível)	-0,0088 (0,0399)	0,825	0,907	fail	fail	0,1517
Preta	Desligamentos (PPML, nível)	0,0445 (0,0309)	0,150	0,341	fail	fail	0,1222
Preta	Fluxo bruto (PPML, nível)	0,0160 (0,0356)	0,653	0,787	fail	fail	0,1346
Preta	Salário real de admissão (log)	-0,0052 (0,0101)	0,608	0,742	fail	fail	0,0343
Preta	Saldo líquido (asinh)	0,2580 (0,2821)	0,361	0,556	fail	fail	0,4386
Parda	Admissões (PPML, nível)	-0,0817 (0,0304)	0,008	0,042	fail	fail	0,1233
Parda	Desligamentos (PPML, nível)	-0,0886 (0,0292)	0,003	0,018	fail	fail	0,1120
Parda	Fluxo bruto (PPML, nível)	-0,0848 (0,0293)	0,004	0,026	fail	fail	0,1151
Parda	Salário real de admissão (log)	-0,0102 (0,0092)	0,270	0,465	fail	pass	0,0276
Parda	Saldo líquido (asinh)	0,1655 (0,2834)	0,560	0,708	fail	fail	0,7276
Amarela	Admissões (PPML, nível)	-0,2770 (0,0576)	< 0,001	< 0,001	fail	fail	0,2262
Amarela	Desligamentos (PPML, nível)	-0,2179 (0,0365)	< 0,001	< 0,001	fail	fail	0,1564
Amarela	Fluxo bruto (PPML, nível)	-0,2487 (0,0466)	< 0,001	< 0,001	fail	fail	0,1901
Amarela	Salário real de admissão (log)	-0,0171 (0,0150)	0,254	0,454	fail	warning	0,0486
Amarela	Saldo líquido (asinh)	0,3108 (0,3305)	0,348	0,552	fail	fail	0,2746
Indígena	Admissões (PPML, nível)	-0,1744 (0,1003)	0,083	0,218	fail	fail	0,2502
Indígena	Desligamentos (PPML, nível)	-0,1172 (0,1140)	0,305	0,507	fail	fail	0,1926
Indígena	Fluxo bruto (PPML, nível)	-0,1455 (0,1049)	0,166	0,370	fail	fail	0,2178
Indígena	Salário real de admissão (log)	-0,0036 (0,0178)	0,838	0,910	pass	pass	0,0473
Indígena	Saldo líquido (asinh)	0,3605 (0,3540)	0,309	0,507	fail	fail	0,1849
Não identificada	Admissões (PPML, nível)	0,0197 (0,0300)	0,510	0,681	fail	fail	0,0675
Não identificada	Desligamentos (PPML, nível)	0,0541 (0,0263)	0,040	0,126	fail	fail	0,0790
Não identificada	Fluxo bruto (PPML, nível)	0,0376 (0,0278)	0,176	0,375	fail	fail	0,0666
Não identificada	Salário real de admissão (log)	0,0415 (0,0107)	< 0,001	0,002	warning	fail	0,0320

Grupo	Resultado	DDD (EP)	p nominal	p BH	Pretrend grupo	Pretrend DDD	MDE 80%
Não identificada	Saldo líquido (asinh)	-0,9754 (0,4922)	0,048	0,142	fail	fail	1,0994

Notas: contrastes DDD pós × exposta × grupo com erro-padrão clusterizado por CBO de quatro dígitos. Família A, de 100 testes, com ajuste de Benjamini-Hochberg; p nominal e p ajustado lado a lado. Cada categoria é contrastada com o seu próprio complemento, e por isso os contrastes não são aditivos: o contraste do agregado Negra, reportado na Tabela 5.2.2, compara pretos e pardos com todo o restante, enquanto o de Parda compara pardos com um complemento que inclui os pretos. 29 dos 30 contrastes têm pretrend fail e exigem cautela. MDE 80% é o efeito mínimo detectável a 80% de poder. N denota observações CBO-mês, não trabalhadores. asinh(saldo) não deve ser interpretado como percentual. Fonte: [results/diagnostics/ddd_multiplicity_results.csv](#) .|

A.4 Idade

Tabela A.4: Contrastes DDD por idade — duas partições

Painel 1 — faixas PNAD/IBGE · Família B, de 30 testes

Grupo	Resultado	DDD (EP)	p nominal	p BH	Pretrend grupo	Pretrend DDD	MDE 80%
18-24	Admissões (PPML, nível)	0,0326 (0,0339)	0,336	0,505	fail	fail	0,1011
18-24	Desligamentos (PPML, nível)	0,0508 (0,0448)	0,258	0,440	fail	fail	0,1246
18-24	Fluxo bruto (PPML, nível)	0,0397 (0,0377)	0,294	0,464	fail	fail	0,1064
18-24	Salário real de admissão (log)	-0,0034 (0,0104)	0,746	0,861	warning	fail	0,0311
18-24	Saldo líquido (asinh)	0,7097 (0,4037)	0,080	0,299	fail	fail	0,5424
25-34	Admissões (PPML, nível)	-0,0207 (0,0158)	0,189	0,399	fail	fail	0,0881
25-34	Desligamentos (PPML, nível)	-0,0275 (0,0180)	0,128	0,399	fail	fail	0,0725
25-34	Fluxo bruto (PPML, nível)	-0,0229 (0,0158)	0,148	0,399	fail	fail	0,0734
25-34	Salário real de admissão (log)	-0,0006 (0,0061)	0,921	0,952	fail	warning	0,0308
25-34	Saldo líquido (asinh)	-0,1245 (0,2233)	0,577	0,722	fail	fail	0,9915
35-44	Admissões (PPML, nível)	0,0297 (0,0216)	0,170	0,399	fail	fail	0,0965
35-44	Desligamentos (PPML, nível)	0,0191 (0,0253)	0,451	0,606	fail	fail	0,0757
35-44	Fluxo bruto (PPML, nível)	0,0257 (0,0230)	0,264	0,440	fail	fail	0,0816
35-44	Salário real de admissão (log)	-0,0083 (0,0065)	0,199	0,399	fail	fail	0,0361
35-44	Saldo líquido (asinh)	-0,0695 (0,2572)	0,787	0,875	fail	pass	0,8570
45-54	Admissões (PPML, nível)	0,0751 (0,0373)	0,045	0,224	fail	fail	0,1317
45-54	Desligamentos (PPML, nível)	0,0455 (0,0339)	0,181	0,399	fail	fail	0,0914

Grupo	Resultado	DDD (EP)	p nominal	p BH	Pretrend grupo	Pretrend DDD	MDE 80%
45-54	Fluxo bruto (PPML, nível)	0,0615 (0,0345)	0,076	0,299	fail	fail	0,1086
45-54	Salário real de admissão (log)	0,0151 (0,0074)	0,043	0,224	warning	fail	0,0319
45-54	Saldo líquido (asinh)	0,3714 (0,3082)	0,229	0,429	fail	fail	0,6379
55-65	Admissões (PPML, nível)	0,0332 (0,0686)	0,628	0,754	fail	fail	0,1904
55-65	Desligamentos (PPML, nível)	-0,0418 (0,0460)	0,365	0,521	fail	fail	0,1106
55-65	Fluxo bruto (PPML, nível)	-0,0067 (0,0535)	0,900	0,952	fail	fail	0,1398
55-65	Salário real de admissão (log)	0,0090 (0,0123)	0,465	0,606	fail	warning	0,0361
55-65	Saldo líquido (asinh)	1,0083 (0,3546)	0,005	0,035	fail	fail	0,3780

Notas do Painel 1: contrastes DDD pós × exposta × grupo sobre as faixas etárias da PNAD/IBGE, com erro-padrão clusterizado por CBO de quatro dígitos. Família B, de 30 testes, com ajuste de Benjamini-Hochberg. A amostra é restrita a trabalhadores de 18 a 65 anos. Nenhum contraste desta partição sobrevive ao ajuste, com exceção do saldo da faixa de 55 a 65 anos, cujo p ajustado é de 0,035. Os 25 contrastes têm pretrend fail. Fonte:

results/diagnostics/ddd_alternative_partitions.csv.

Painel 2 — coortes Canaries · Família A, de 100 testes

Grupo	Resultado	DDD (EP)	p nominal	p BH	Pretrend grupo	Pretrend DDD	MDE 80%
22-25	Admissões (PPML, nível)	-0,0189 (0,0269)	0,482	0,652	fail	fail	0,0905
22-25	Desligamentos (PPML, nível)	0,0002 (0,0367)	0,995	0,995	fail	fail	0,1010
22-25	Fluxo bruto (PPML, nível)	-0,0107 (0,0302)	0,723	0,850	fail	fail	0,0872
22-25	Salário real de admissão (log)	-0,0004 (0,0083)	0,964	0,974	pass	fail	0,0294
22-25	Saldo líquido (asinh)	0,4145 (0,4033)	0,305	0,507	fail	fail	0,6972
26-30	Admissões (PPML, nível)	-0,0105 (0,0139)	0,450	0,616	fail	fail	0,0877
26-30	Desligamentos (PPML, nível)	-0,0125 (0,0113)	0,266	0,465	fail	fail	0,0751
26-30	Fluxo bruto (PPML, nível)	-0,0115 (0,0116)	0,323	0,522	fail	fail	0,0739
26-30	Salário real de admissão (log)	0,0070 (0,0081)	0,388	0,581	fail	fail	0,0295
26-30	Saldo líquido (asinh)	0,2284 (0,1840)	0,215	0,418	fail	fail	0,8193
31-34	Admissões (PPML, nível)	0,0253 (0,0122)	0,038	0,125	fail	fail	0,0888
31-34	Desligamentos (PPML, nível)	0,0202 (0,0121)	0,097	0,245	fail	fail	0,0706
31-34	Fluxo bruto (PPML, nível)	0,0231 (0,0115)	0,046	0,139	fail	fail	0,0734

Grupo	Resultado	DDD (EP)	p nominal	p BH	Pretrend grupo	Pretrend DDD	MDE 80%
31-34	Salário real de admissão (log)	-0,0105 (0,0070)	0,135	0,325	fail	fail	0,0329
31-34	Saldo líquido (asinh)	0,4299 (0,1942)	0,028	0,095	fail	fail	0,8533
35-40	Admissões (PPML, nível)	0,0353 (0,0148)	0,017	0,062	fail	fail	0,0930
35-40	Desligamentos (PPML, nível)	0,0275 (0,0166)	0,098	0,245	fail	fail	0,0745
35-40	Fluxo bruto (PPML, nível)	0,0319 (0,0154)	0,039	0,125	fail	fail	0,0790
35-40	Salário real de admissão (log)	0,0026 (0,0068)	0,699	0,832	fail	warning	0,0310
35-40	Saldo líquido (asinh)	0,2605 (0,2006)	0,195	0,398	fail	fail	0,8033
41-49	Admissões (PPML, nível)	0,0841 (0,0236)	< 0,001	0,004	fail	fail	0,1125
41-49	Desligamentos (PPML, nível)	0,0699 (0,0245)	0,005	0,027	fail	fail	0,0829
41-49	Fluxo bruto (PPML, nível)	0,0776 (0,0235)	0,001	0,009	fail	fail	0,0942
41-49	Salário real de admissão (log)	0,0010 (0,0076)	0,892	0,925	fail	fail	0,0383
41-49	Saldo líquido (asinh)	0,3007 (0,2457)	0,222	0,419	fail	fail	0,7140
50+	Admissões (PPML, nível)	0,0663 (0,0533)	0,214	0,418	fail	fail	0,1664
50+	Desligamentos (PPML, nível)	0,0069 (0,0377)	0,855	0,919	fail	fail	0,0994
50+	Fluxo bruto (PPML, nível)	0,0357 (0,0430)	0,407	0,581	fail	fail	0,1265
50+	Salário real de admissão (log)	0,0136 (0,0103)	0,189	0,394	fail	fail	0,0305
50+	Saldo líquido (asinh)	1,2056 (0,3571)	0,001	0,007	fail	fail	0,4846

Notas do Painel 2: contrastes DDD *pós × exposta × grupo* sobre as coortes etárias do artigo de referência, com erro-padrão clusterizado por CBO de quatro dígitos. Família A, de 100 testes, com ajuste de Benjamini-Hochberg. Os dois painéis desta tabela pertencem a famílias distintas porque as partições se sobrepõem: testar a faixa de 18 a 24 anos e testar a de 22 a 25 não são hipóteses independentes, e reuni-las num único denominador inflaria a família sem ganho informacional. O contraste que sobrevive ao ajuste é o da faixa de 41 a 49 anos, positivo nos três outcomes de fluxo. Os 30 contrastes têm pretrend *fail*. MDE 80% é o efeito mínimo detectável a 80% de poder. N denota observações CBO-mês, não trabalhadores. Fonte: [results/diagnostics/ddd_multiplicity_results.csv](#).

A.5 Escolaridade

Tabela A.5: Contrastes DDD por escolaridade

Contrastes DDD · Família A, de 100 testes

Grupo	Resultado	DDD (EP)	p nominal	p BH	Pretrend grupo	Pretrend DDD	MDE 80%
Fundamental ou menos	Admissões (PPML, nível)	0,1231 (0,0502)	0,015	0,055	fail	fail	0,1492

Grupo	Resultado	DDD (EP)	p nominal	p BH	Pretrend grupo	Pretrend DDD	MDE 80%
Fundamental ou menos	Desligamentos (PPML, nível)	0,1321 (0,0531)	0,013	0,055	fail	fail	0,1316
Fundamental ou menos	Fluxo bruto (PPML, nível)	0,1284 (0,0504)	0,011	0,051	fail	fail	0,1370
Fundamental ou menos	Salário real de admissão (log)	0,0349 (0,0142)	0,014	0,055	fail	fail	0,0405
Fundamental ou menos	Saldo líquido (asinh)	0,9560 (0,3619)	0,009	0,043	fail	fail	0,4687
Médio	Admissões (PPML, nível)	-0,0057 (0,0344)	0,868	0,923	fail	fail	0,0882
Médio	Desligamentos (PPML, nível)	-0,0333 (0,0288)	0,248	0,451	fail	fail	0,0862
Médio	Fluxo bruto (PPML, nível)	-0,0187 (0,0294)	0,525	0,691	fail	fail	0,0827
Médio	Salário real de admissão (log)	-0,0014 (0,0112)	0,902	0,925	fail	fail	0,0342
Médio	Saldo líquido (asinh)	0,1938 (0,2481)	0,435	0,605	fail	fail	0,9134
Superior	Admissões (PPML, nível)	-0,1108 (0,0451)	0,015	0,055	fail	fail	0,1041
Superior	Desligamentos (PPML, nível)	-0,1064 (0,0435)	0,015	0,055	fail	fail	0,1021
Superior	Fluxo bruto (PPML, nível)	-0,1083 (0,0418)	0,010	0,048	fail	fail	0,0929
Superior	Salário real de admissão (log)	0,0076 (0,0128)	0,551	0,707	fail	warning	0,0262
Superior	Saldo líquido (asinh)	-0,8421 (0,2689)	0,002	0,015	fail	fail	0,8915

Notas: contrastes DDD pós × exposta × grupo, com erro-padrão clusterizado por CBO de quatro dígitos. Família A, de 100 testes, com ajuste de Benjamini-Hochberg; p nominal e p ajustado lado a lado. Note-se que quatro dos cinco contrastes do ensino superior e quatro dos cinco do fundamental têm p ajustado entre 0,043 e 0,055 — isto é, na fronteira do limiar convencional. 15 dos 15 contrastes têm pretrend fail. MDE 80% é o efeito mínimo detectável a 80% de poder. N denota observações CBO-mês, não trabalhadores. Fonte: [results/diagnostics/ddd_multiplicity_results.csv](#).

Notas gerais do Apêndice A: os coeficientes DDD correspondem à interação pós × tratamento × grupo e comparam cada grupo ao seu complemento. Os erros-padrão, entre parênteses, são clusterizados por CBO de quatro dígitos. * p<0,10; ** p<0,05; *** p<0,01. N denota observações CBO-mês, não trabalhadores. O suporte adequado requer pelo menos 20 CBOs tratadas e 50 de controle; o suporte limitado requer 10 e 25; valores inferiores são classificados como insuficientes. Em dimensões binárias, os DDDs dos dois grupos são espelhados por construção e não constituem testes independentes.

A.6 Renda ocupacional pré-tratamento

Tabela A.6: Contrastes DDD por renda ocupacional pré-tratamento

Contrastes DDD · Família A, de 100 testes

Grupo	Resultado	DDD (EP)	p nominal	p BH	Pretrend grupo	Pretrend DDD	MDE 80%
Até 2 SM	Admissões (PPML, nível)	0,1183 (0,0793)	0,136	0,325	fail	fail	0,0902
Até 2 SM	Desligamentos (PPML, nível)	0,0112 (0,0952)	0,906	0,925	fail	fail	0,0842

Grupo	Resultado	DDD (EP)	p nominal	p BH	Pretrend grupo	Pretrend DDD	MDE 80%
Até 2 SM	Fluxo bruto (PPML, nível)	0,0676 (0,0863)	0,434	0,605	fail	fail	0,0839
Até 2 SM	Salário real de admissão (log)	-0,0062 (0,0236)	0,792	0,907	fail	warning	0,0393
Até 2 SM	Saldo líquido (asinh)	1,6638 (0,8627)	0,055	0,156	fail	fail	1,0034
Mais de 2 a 5 SM	Admissões (PPML, nível)	-0,1474 (0,0779)	0,059	0,164	fail	fail	0,1893
Mais de 2 a 5 SM	Desligamentos (PPML, nível)	-0,0543 (0,0911)	0,552	0,707	fail	fail	0,2280
Mais de 2 a 5 SM	Fluxo bruto (PPML, nível)	-0,1033 (0,0836)	0,217	0,418	fail	fail	0,2069
Mais de 2 a 5 SM	Salário real de admissão (log)	-0,0031 (0,0256)	0,904	0,925	fail	fail	0,0734
Mais de 2 a 5 SM	Saldo líquido (asinh)	-1,2692 (0,9244)	0,171	0,371	warning	fail	2,3802
Mais de 5 SM	Admissões (PPML, nível)	0,0947 (0,1133)	0,404	0,581	fail	fail	0,3048
Mais de 5 SM	Desligamentos (PPML, nível)	0,2486 (0,1375)	0,071	0,193	not_estimated	fail	0,3364
Mais de 5 SM	Fluxo bruto (PPML, nível)	0,1699 (0,1153)	0,142	0,329	fail	fail	0,2702
Mais de 5 SM	Salário real de admissão (log)	0,0643 (0,0242)	0,008	0,043	fail	fail	0,1102
Mais de 5 SM	Saldo líquido (asinh)	-2,4186 (2,0104)	0,230	0,426	fail	fail	6,7640

*Notas: contrastes DDD pós × exposta × grupo, com erro-padrão clusterizado por CBO de quatro dígitos. Família A, de 100 testes, com ajuste de Benjamini-Hochberg; p nominal e p ajustado lado a lado. A coluna de suporte é parte do resultado e não um detalhe técnico. O único contraste desta tabela que sobrevive ao ajuste — o salário da faixa acima de 5 salários mínimos, com p ajustado de 0,043 — repousa sobre 3 ocupações tratadas e 6 de controle, e por isso não é usado como base de afirmação no corpo do texto. A faixa intermediária tem suporte **limited**, com 26 CBOs tratadas e 32 de controle. **not_estimated** no pretrend registra que a inclinação GLS não é identificada naquela célula. 15 dos 15 contrastes têm pretrend **fail** ou suporte insuficiente. **MDE 80%** é o efeito mínimo detectável a 80% de poder; nas faixas de suporte fino ele é grande o bastante para que a ausência de resultado seja ausência de precisão, e não ausência de efeito. N denota observações CBO-mês, não trabalhadores. Fonte:*

results/diagnostics/ddd_multiplicity_results.csv.

REFERÊNCIAS

- AGARWAL, Nikhil; MOEHRING, Alex; RAJPURKAR, Pranav; SALZ, Tobias. **Combining human expertise with artificial intelligence: Experimental evidence from radiology**. Cambridge, MA: National Bureau of Economic Research, jul. 2023. DOI: <https://doi.org/10.3386/w31422>. Disponível em: <https://www.nber.org/papers/w31422>. Acesso em: 25 jul. 2026.
- ALDASORO, Iñaki; GAMBACORTA, Leonardo; PAL, Rozalia; REVOLTELLA, Debora; WEISS, Christoph; WOLSKI, Marcin. **AI adoption, productivity and employment: Evidence from European firms**. Luxembourg: European Investment Bank, jan. 2026. DOI: <https://doi.org/10.2867/1772538>. Disponível em: <https://doi.org/10.2867/1772538>. Acesso em: 25 jul. 2026.
- APPEL, Ruth; MASSENKOFF, Maxim; MCCRORY, Peter; MCCAIN, Miles; HELLER, Ryan; NEYLON, Tyler; TAMKIN, Alex. **Anthropic Economic Index report: Economic primitives**. [S. l.]: Anthropic, 15 jan. 2026. Disponível em: <https://www.anthropic.com/research/anthropic-economic-index-january-2026-report>. Acesso em: 25 jul. 2026.

AUTOR, David H.; LEVY, Frank; MURNANE, Richard J. The skill content of recent technological change: An empirical exploration. **The Quarterly Journal of Economics**, [s. l.], v. 118, n. 4, p. 1279-1333, nov. 2003. DOI: <https://doi.org/10.1162/003355303322552801>. Disponível em: <https://academic.oup.com/qje/article/118/4/1279/1925105>. Acesso em: 25 jul. 2026.

BENÍTEZ, Miguel; PARRADO, Eric. **Mirror, Mirror on the Wall: Which Jobs Will AI Replace After All?: A New Index of Occupational Exposure**. [S. l.]: Inter-American Development Bank, 27 ago. 2024. DOI: <https://doi.org/10.18235/0013125>. Disponível em: <https://publications.iadb.org/en/mirror-mirror-wall-which-jobs-will-ai-replace-after-all-new-index-occupational-exposure>. Acesso em: 25 jul. 2026.

BICK, Alexander; BLANDIN, Adam; DEMING, David J. **The rapid adoption of generative AI**. [S. l.]: Federal Reserve Bank of St. Louis, 2024. DOI: <https://doi.org/10.20955/wp.2024.027>. Disponível em: <https://doi.org/10.20955/wp.2024.027>. Acesso em: 25 jul. 2026.

BRASIL. **Decreto nº 12.342, de 30 de dezembro de 2024**. Dispõe sobre o valor do salário mínimo a vigorar a partir de 1º de janeiro de 2025. Brasília, DF: Presidência da República, 2024. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2023-2026/2024/decreto/d12342.htm. Acesso em: 25 jul. 2026.

BRYNJOLFSSON, Erik; CHANDAR, Bharat; CHEN, Ruyu. **Canaries in the coal mine? Six facts about the recent employment effects of artificial intelligence**. [S. l.]: Stanford Digital Economy Lab, 13 nov. 2025. Disponível em: <https://digitaleconomy.stanford.edu/publication/canaries-in-the-coal-mine-six-facts-about-the-recent-employment-effects-of-artificial-intelligence/>. Acesso em: 25 jul. 2026.

CHANDAR, Bharat. **Tracking employment changes in AI-exposed jobs**. [S. l.]: Stanford Digital Economy Laboratory, 3 jun. 2025. DOI: <https://doi.org/10.2139/ssrn.5384519>. Disponível em: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=5384519. Acesso em: 25 jul. 2026.

ELOUNDOU, Tyna; MANNING, Sam; MISHKIN, Pamela; ROCK, Daniel. **GPTs are GPTs: An Early Look at the Labor Market Impact Potential of Large Language Models**. arXiv:2303.10130. [S. l.]: arXiv, 21 ago. 2023. DOI: <https://doi.org/10.48550/arXiv.2303.10130>. Disponível em: <http://arxiv.org/abs/2303.10130>. Acesso em: 25 jul. 2026.

GMYREK, Pawel; BERG, Janine; KAMIŃSKI, Karol; KONOPCZYŃSKI, Filip; ŁADNA, Agnieszka; NAFRADI, Balint; ROSŁANIEC, Konrad; TROSZYŃSKI, Marek. **Generative AI and jobs: A refined global index of occupational exposure**. Geneva: International Labour Organization, 20 maio 2025. DOI: <https://doi.org/10.54394/HETP0387>. Disponível em: <https://www.ilo.org/publications/generative-ai-and-jobs-refined-global-index-occupational-exposure>. Acesso em: 25 jul. 2026.

HOSSEINI MAASOUM, Seyed Mahdi; LICHTINGER, Guy. **Generative AI as seniority-biased technological change: Evidence from U.S. résumé and job posting data**. [S. l.]: SSRN, 31 ago. 2025. DOI: <https://doi.org/10.2139/ssrn.5425555>. Disponível em: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=5425555. Acesso em: 25 jul. 2026.

HUMLUM, Anders; VESTERGAARD, Emilie. **Still waters, rapid currents: Early labor market transformation under generative AI**. Cambridge, MA: National Bureau of Economic Research, maio 2025. DOI: <https://doi.org/10.3386/w33777>. Disponível em: <https://www.nber.org/papers/w33777>. Acesso em: 25 jul. 2026.

KLEIN TEESELINK, Bouke. **Generative AI and labor market outcomes: Evidence from the United Kingdom**. [S. l.]: SSRN, 22 set. 2025. DOI: <https://doi.org/10.2139/ssrn.5516798>. Disponível em: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=5516798. Acesso em: 25 jul. 2026.

OSORIO, Rafael Guerreiro. **O sistema classificatório de “cor ou raça” do IBGE**. Brasília, DF: Instituto de Pesquisa Econômica Aplicada, nov. 2003. Disponível em: <https://repositorio.ipea.gov.br/bitstreams/e09cc868-669f-4064-b396-693e22e0ce07/download>. Acesso em: 25 jul. 2026.

 [Introdução \(Reescrita\)](#)

 [Mensuração da Exposição Ocupacional à IA \(Reescrita\)](#)